


UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



POROVNANIE DVOCH RÔZNYCH SLOVNÝCH SIETÍ
VYTVORENÝCH NA BÁZE TOHO ISTÉHO TEXTU
BAKALÁRSKA PRÁCA

2026

SEBASTIÁN MURAJDA

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

POROVNANIE DVOCH RÔZNYCH SLOVNÝCH SIETÍ
VYTVORENÝCH NA BÁZE TOHO ISTÉHO TEXTU
BAKALÁRSKA PRÁCA

Študijný program: Aplikovaná informatika
Študijný odbor: Informatika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: doc. RNDr. Mária Markošová, PhD.

Bratislava, 2026
Sebastián Murajda



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Sebastián Murajda
Študijný program: aplikovaná informatika (Jednoodborové štúdium, bakalársky I. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: bakalárska
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Porovnanie dvoch rôznych slovných sietí vytvorených na báze toho istého textu.
Comparison of two different word webs based on the same text.

Anotácia: Študent vytvorí slovnú sieť na báze anglického, poprípade aj iného textu. Potom túto sieť zanalyzuje metódami z teórie grafov. Porovná ako sa parametre siete bez interpunkčných znamienok (uzly siete sú len slová) a s interpunkčnými znamienkami (uzly siete sú slová aj znamienka) zmenia.

Cieľ: Porovnávanie štruktúry dvoch slovných sietí vytvorených z toho istého textu.

Literatúra: Kulig and others. In narrative texts punctuation marks obey the same statistics as words, Information Sciences
Volume 375, 1 January 2017, Pages 98-113

Kľúčové

slová: slovná sieť, distribúcie, interpunkčné znamienka

Vedúci: doc. RNDr. Mária Markošová, PhD.

Katedra: FMFI.KAI - Katedra aplikovanej informatiky

Vedúci katedry: doc. RNDr. Tatiana Jajcayová, PhD.

Dátum zadania: 21.02.2025

Dátum schválenia: 12.02.2026

doc. RNDr. Damas Gruska, PhD.
garant študijného programu

.....
študent

.....
vedúci práce

Čestné vyhlásenie: Čestne vyhlasujem, že celú bakalársku prácu na tému „Porovnanie dvoch rôznych slovných sietí vytvorených na báze toho istého textu“, vrátane všetkých jej príloh a obrázkov, som vypracoval/vypracovala samostatne, a to s použitím literatúry uvedenej v priloženom zozname.

Bratislava, 2026

podpis:

Podakovanie: Chcel by som sa poďakovať svojej školiteľke doc. RNDr. Márii Markošovej, PhD., za odborné vedenie, cenné rady a pripomienky, ktoré mi pomohli pri vypracovaní tejto bakalárskej práce.

Abstrakt

Táto bakalárska práca sa zaoberá porovnaním dvoch typov slovných sietí vytvorených z rovnakej textovej predlohy. Cieľom práce bolo analyzovať, ako sa mení štruktúra jazykových sietí pri zahrnutí interpunkčných znamienok do siete v porovnaní so sieťou tvorenou iba slovami. V teoretickej časti sú predstavené základy teórie grafov, matematickej lingvistiky a teórie komplexných sietí so zameraním na slovné siete a ich vlastnosti. Praktická časť sa venuje spracovaniu textových dát, tvorbe syntaktických slovných sietí a výpočtu vybraných topologických metrík, ako sú hustota siete, priemerný stupeň vrcholov, koeficient zhukovania či priemerná najkratšia vzdialenosť. Súčasťou analýzy bolo aj skúmanie frekvencie slov pomocou Zipfovho a Heapsovho zákona a analýza distribúcie stupňov uzlov. Výsledky ukázali, že zahrnutie interpunkčných znamienok ovplyvňuje štruktúru siete a mení niektoré jej topologické charakteristiky, pričom analyzované siete si zároveň zachovávajú vlastnosti typické pre reálne komplexné siete, najmä bezškálovosť a efekt malého sveta. Práca zároveň skúma vplyv lematizácie textu na výslednú štruktúru sietí.

Kľúčové slová: slovné siete, interpunkcia, kvantitatívna lingvistika, distribúcia stupňov uzlov, lematizácia

Abstract

This bachelor thesis focuses on the comparison of two types of word networks created from the same text source. The aim of the thesis was to analyze how the structure of language networks changes when punctuation marks are included in the network compared to a network consisting only of words. The theoretical part introduces the fundamentals of graph theory, mathematical linguistics, and complex network theory, with a focus on word networks and their properties. The practical part deals with text data preprocessing, the construction of syntactic word networks, and the calculation of selected topological metrics such as network density, average node degree, clustering coefficient, and average shortest path length. The analysis also includes the study of word frequency using Zipf's and Heaps' laws, as well as the analysis of node degree distribution. The results showed that the inclusion of punctuation marks affects the network structure and changes some of its topological characteristics, while the networks still preserve properties typical of real complex networks, especially scale-free behavior and the small-world effect. The thesis also examines the influence of text lemmatization on the resulting network structure.

Keywords: word networks, punctuation, quantitative linguistics, node degree distribution, lemmatization

Obsah

Úvod	1
1 Teoretické východiská	3
1.1 Teória grafov a ich analýza	3
1.1.1 Základné pojmy grafov	3
1.1.2 Topologické metriky	6
1.2 Matematická lingvistika	8
1.2.1 Kvantitatívna lingvistika	9
1.2.2 Algebraická lingvistika	11
1.2.3 Počítačová lingvistika	12
1.3 Siete	12
1.3.1 Reálne siete	12
1.3.2 Vlastnosti reálnych sietí	13
1.3.3 Slovné siete	16
1.4 Interpunkcia v analýze textu	18
1.4.1 Štatistická povaha interpunkcie a jej význam v sieťach	19
2 Metodika a spracovanie dát	21
2.1 Východiskové texty	21
2.1.1 Zoznam použitých jazykových verzií a ich vlastnosti	21
2.2 Predspracovanie textu	23
2.3 Tvorba slovných sietí a výpočet charakteristík	25
2.3.1 Použité nástroje a knižnice	25
2.3.2 Princíp a postup tvorby slovnej siete	27
2.3.3 Analýza distribúcie stupňov uzlov	28
2.3.4 Aplikovanie Zipfovho zákona	29
2.3.5 Aplikovanie Heapsovho zákona	30
3 Porovnanie sietí a výsledky	31
3.1 Základné charakteristiky sietí	31
3.1.1 Doplnkové metriky	33

3.2	Frekvencia slov a slovná zásoba	35
3.2.1	Najfrekventovanejšie prvky	35
3.2.2	Zipfov a Heapsov zákon	37
3.3	Distribúcia stupňov uzlov	40
3.4	Vplyv lematizácie textov na sieť	45
3.4.1	Základné charakteristiky lematizovaných sietí	46
3.4.2	Topologické metriky lematizovaných sietí	47
3.4.3	Distribúcia stupňov uzlov po lematizácii	48
Záver		53
Literatúra		57
Zdrojový kód programu		61

Zoznam obrázkov

1.1	Ilustrácia štruktúry neorientovaného grafu s 3 vrcholmi.	4
1.2	Príklad syntaktickej siete vytvorenej z úryvku diela <i>Premena</i> v slovenskom jazyku od <i>F. Kafku</i> v aplikácii Gephi. Smerovanie textu je v grafe naznačené farebnými indikátormi: zelená šípka označuje počiatočný bod úryvku a červená šípka jeho koniec.	17
2.1	Ukážka Gephi rozhrania a vizualizácia slovnej siete	27
2.2	Ukážka nesprávne vizualizovanej distribúcie stupňov uzlov v log-log mierke	29
3.1	Zobrazenie Zipfovho zákona pre jazykové verzie bez interpunkcie – závislosť pravdepodobnosti výskytu slova $P(R)$ od jeho poradia R v logaritmickej mierke. Čierne body predstavujú empirické frekvencie slov, červená prerušovaná priamka znázorňuje správanie podľa Zipfovho zákona s exponentom α	38
3.2	Zobrazenie Heapsovho zákona pre jazykové verzie bez interpunkcie – závislosť počtu rôznych slov $V(L)$ od celkového počtu slov L v logaritmickej miere. Čierne body predstavujú empirické dáta, ktoré ilustrujú rast slovnej zásoby so zvyšujúcou sa veľkosťou textu a červená prerušovaná priamka znázorňuje správanie podľa Heapsovho zákona s exponentom β	39
3.3	Zobrazenie Zipfovho zákona pre jazykové verzie s interpunkciou – závislosť pravdepodobnosti výskytu slova $P(R)$ od jeho poradia R v logaritmickej mierke. Čierne body predstavujú empirické frekvencie slov, červená prerušovaná priamka znázorňuje správanie podľa Zipfovho zákona s exponentom α	41
3.4	Distribúcia stupňov uzlov pre jazykové verzie bez interpunkcie - závislosť pravdepodobnosti $P(k)$ od stupňa uzla k v log-log mierke. Čierne body predstavujú empirické dáta, červená prerušovaná priamka znázorňuje správanie podľa mocninového zákona s exponentom γ	42

3.5	Distribúcia stupňov uzlov pre jazykové verzie so zahrnutím interpunkcie - závislosť pravdepodobnosti $P(k)$ od stupňa uzla k v log-log mierke. Čierne body predstavujú empirické dáta, červená prerušovaná priamka znázorňuje správanie podľa mocninového zákona s exponentom γ	44
3.6	Distribúcia stupňov uzlov pre siete z lematizovaných textov bez interpunkcie - závislosť pravdepodobnosti $P(k)$ od stupňa uzla k v log-log mierke. Čierne body predstavujú empirické dáta, červená prerušovaná priamka znázorňuje správanie podľa mocninového zákona s exponentom γ	49
3.7	Distribúcia stupňov uzlov pre siete z lematizovaných textov s interpunkciou - závislosť pravdepodobnosti $P(k)$ od stupňa uzla k v log-log mierke. Čierne body predstavujú empirické dáta, červená prerušovaná priamka znázorňuje správanie podľa mocninového zákona s exponentom γ	51

Zoznam tabuliek

2.1	Základné štatistiky analyzovaných textov	22
2.2	Zoznam interpunkčných znamienok zachovaných ako samostatné uzly .	23
3.1	Základné charakteristiky sietí (počet uzlov n , počet hrán e a hustota ρ) z textov jednotlivých jazykov bez interpunkcie	32
3.2	Základné charakteristiky sietí (počet uzlov n , počet hrán e a hustota ρ) z textov jednotlivých jazykov s interpunkciou	33
3.3	Priemerný stupeň $\langle k \rangle$, koeficient zhlukovania C a priemerná najkratšia vzdialenosť $\langle d \rangle$ pre jazyky s označením bez/s pre siete bez interpunkcie a s ňou	33
3.4	Najfrekventovanejšie tokeny pre jazykové verzie bez zahrnutia interpunkcií	35
3.5	Najfrekventovanejšie tokeny pre jazykové verzie so zahrnutím interpunkcie	36
3.6	Poradie interpunkčných znamienok podľa frekvencie výskytu v jednotli- vých jazykoch. V zátvorkách je uvedená absolútna frekvencia.	37
3.7	Očakávané hodnoty Heapsovho exponentu pre jednotlivé jazyky vyrá- tané podľa exponentu α	40
3.8	Očakávané hodnoty škálovacieho exponentu γ pre siete jednotlivých ja- zykov bez interpunkcie vyrátané podľa exponentu α	45
3.9	Očakávané hodnoty škálovacieho exponentu γ pre siete jednotlivých ja- zykov s interpunkciou vyrátané podľa exponentu α	45
3.10	Základné charakteristiky sietí z lematizovaných textov (počet uzlov n , počet hrán e a hustota ρ) pre jednotlivé jazyky. Stĺpce „bez“ a „s“ ozna- čujú siete bez interpunkcie a s interpunkciou.	46
3.11	Priemerný stupeň $\langle k \rangle$, koeficient zhlukovania C a priemerná najkratšia vzdialenosť $\langle d \rangle$ pre lematizované texty s označením bez/s pre siete bez interpunkcie a s interpunkciou	47

Úvod

Jazyk predstavuje jeden z najzložitejších systémov ľudskej komunikácie. Každý deň produkujeme a spracúvame veľké množstvo slov, pričom mozog túto činnosť vykonáva takmer bez námahy. Za touto jednoduchosťou sa však skrýva komplexná štrukturálna organizácia, ktorú sa veda snaží postupne odhaľovať. Táto štruktúra jazyka je predmetom skúmania viacerých vedeckých disciplín, ako sú lingvistika, kognitívna veda a informatika. Jedným z prístupov k jej pochopeniu je reprezentácia jazyka vo forme siete, v ktorej slová predstavujú uzly a ich vzájomné vzťahy hrany.

V posledných desaťročiach sa pri analýze jazykových štruktúr začali využívať metódy teórie grafov a komplexných sietí, ktoré umožňujú modelovať vzťahy medzi jednotlivými slovami a skúmať vlastnosti prirodzeného jazyka z kvantitatívneho hľadiska. Ferrer i Cancho a Solé preukázali, že syntaktické slovné siete majú architektúru malého sveta s krátkou priemernou vzdialenosťou medzi slovami a zároveň bezškálovú distribúciu stupňov uzlov, čo ich zaraďuje do rovnakej triedy komplexných sietí ako napríklad internet či sociálne siete. Analýza takýchto sietí umožňuje lepšie pochopiť organizáciu prirodzeného jazyka a vzťahy medzi jeho jednotlivými prvkami. Súčasne sa v kvantitatívnej lingvistike ustálili empirické zákonitosti, ako Zipfov zákon o frekvencii slov či Heapsov zákon o raste slovnej zásoby, ktoré platia pozoruhodne konzistentne naprieč jazykmi aj textovými žánrami.

Významnú úlohu pri spracovaní textu zohráva aj interpunkcia, ktorá okrem gramatickej funkcie ovplyvňuje štruktúru textu a vzťahy medzi slovami. Napriek tomu bývajú interpunkčné znamienka pri tvorbe jazykových sietí často odstraňované alebo ignorované. Výskum Kuliga a kol. však ukázal, že interpunkcia v naratívnych textoch sleduje rovnaké štatistické zákonitosti ako slová a v rebríčkoch frekvencie obsadzuje popredné miesta, napríklad čiarka a bodka v mnohých európskych jazykoch prekonávajú frekvenciu aj tých najčastejších funkčných slov. Kulig a kol. sa pritom zamerali najmä na frekvenčné vlastnosti interpunkcie a jej vplyv na škálovanie Zipfovho zákona, no otázka, ako sa zahrnutie interpunkcie prejaví na topologickej štruktúre slovnej siete ako celku, zostala otvorená. Táto práca na ich výskum nadväzuje a rozširuje ho o analýzu distribúcie stupňov uzlov a ďalších topologických metrík, čo umožňuje komplexnejšie posúdiť, do akej miery interpunkcia mení charakter jazykovej siete. Skúmanie jazykových sietí môže prispieť k lepšiemu pochopeniu štruktúry prirodzeného jazyka a zároveň nájst

využitie pri spracovaní prirodzeného jazyka a analýze textov.

Cieľom tejto bakalárskej práce je analyzovať a porovnať vlastnosti slovných sietí vytvorených z rovnakého textového základu pri dvoch rôznych prístupoch — so zahrnutím interpunkčných znamienok a bez ich zahrnutia. Na tento účel bolo využitých šesť jazykových verzií Kafkovej novely *Premena*, reprezentujúcich germánsku a románsku jazykovú rodinu, čo umožňuje izolovať vplyv jazykovej štruktúry od vplyvu obsahu textu. Súčasťou práce je skúmanie základných topologických metrík sietí, analýza distribúcie stupňov uzlov a overenie platnosti Zipfovho a Heapsovho zákona. Práca sa zároveň venuje vplyvu lematizácie textu na výslednú štruktúru vytvorených sietí.

Teoretická časť práce predstavuje základné pojmy z teórie grafov, komplexných sietí a matematickej lingvistiky so zameraním na jazykové siete a ich vlastnosti. Praktická časť opisuje proces spracovania textových dát, tvorbu syntaktických slovných sietí a následnú analýzu ich topologických charakteristík pomocou vybraných metrík a štatistických metód.

Kapitola 1

Teoretické východiská

Táto kapitola predstavuje teoretický základ práce a vysvetľuje pojmy, z ktorých vychádza analýza jazykových dát pomocou sietí. Keďže práca spája matematiku, informatiku a lingvistiku, je najprv potrebné objasniť základné koncepty z teórie grafov, matematickej lingvistiky a teórie sietí.

V prvej časti kapitoly sa venujeme teórii grafov, ktorá poskytuje nástroje na opis objektov a vzťahov medzi nimi. Predstavíme základné definície, typy grafov a vybrané vlastnosti a metriky, ktoré sú dôležité pre neskoršiu analýzu sietí.

Následujúca časť sa zameriava na matematickú lingvistiku, najmä na kvantitatívny pohľad na jazyk ako systém, v ktorom sa prejavujú pravidelnosti opísateľné pomocou matematických a štatistických zákonov.

V závere kapitoly prechádzame k sieťam ako modelom reálnych komplexných systémov. Charakterizujeme základné vlastnosti reálnych sietí, ako sú malá hustota, bezškálovosť, „malý svet“ či zhlukovanie. Tieto poznatky následne aplikujeme na jazyk pomocou slovných sietí, ktoré umožňujú zachytiť vzťahy medzi slovami a tvoria základ pre analytickú časť práce.

1.1 Teória grafov a ich analýza

Teória grafov je široké odvetvie matematiky s aplikáciami v informatike, ktoré sa zaoberá štúdiom grafov, ich vlastností a rôznych aspektov. V tejto podkapitole objasníme všetky potrebné definície so zameraním na pojmy a vzťahy v grafoch nevyhnutné pre pochopenie tejto práce. Definície a teoretické poznatky sa týkajú hlavne jednoduchých grafov.

1.1.1 Základné pojmy grafov

Graf je abstraktná štruktúra, ktorá modeluje rôzne vzťahy medzi objektami. Každý graf sa skladá z dvoch základných prvkov [23]:

- **vrcholy** – predstavujú jednotlivé objekty alebo body grafu, zvykneme ich nazývať aj **uzly**,
- **hrany** – označujú spojenia medzi objektmi, ktoré nesú informáciu o ich vzájomnom vzťahu.

Definujme si graf G a formálne ho môžeme zapísať ako usporiadanú dvojicu $(V, E) = G$ [23], kde:


- V je množina vrcholov,
- E je množina, ktorá obsahuje dvojice vrcholov predstavujúce hrany, pričom hrana vyjadruje vzťah medzi týmito vrcholmi. Platí, že E je množina dvojprvkových podmnožín V , teda $E \subseteq [V]^2$ [6].

Hrany grafu delíme na [23]:

- **orientované**, v ktorých je fixné poradie spojených vrcholov dôležité – vrchol v_1 je počiatočný a v_2 je koncový a zapisujeme ich ako usporiadané dvojice vrcholov (v_1, v_2) ,
- **neorientované**, v ktorých poradie spájaných vrcholov nie je dôležité, zapisujeme $\{v_1, v_2\}$ a teda táto hrana spája v_1 s v_2 a naopak.

Ak graf pozostáva výhradne z orientovaných hrán, tento typ sa nazýva **orientovaný graf** a naopak, ak je tvorený len neorientovanými hranami, ide o **neorientovaný graf**.

Graf znázorňujeme pomocou diagramu, v ktorom bodkami alebo krúžkami reprezentujúcimi vrcholy a čiarami spájajúcimi príslušné dvojice vrcholov reprezentujúcimi hrany [6], pozri obrázok 1.1.



Obr. 1.1: Ilustrácia štruktúry neorientovaného grafu s 3 vrcholmi.

Špeciálnym a pre túto prácu kľúčovým typom je **jednoduchý graf**. Tento graf pozostáva z **neprázdnej konečnej** množiny vrcholov $V(G)$ a **konečnej** množiny $E(G)$ tvorenej z **neusporiadaných** dvojíc vrcholov. Keďže sú hrany definované neusporiadanými dvojicami, podľa tejto definície budeme jednoduchý graf považovať za **neorientovaný** [33]. Okrem toho, pre jednoduchý graf platí, že spĺňa nasledujúce podmienky [23]:

- neobsahuje **slučky** – hrany, ktorých počiatkový aj koncový uzol je rovnaký, teda spája vrchol so samým sebou,
- neobsahuje **viacnásobné hrany** – situácie, kedy medzi dvoma vrcholmi existuje viac ako jedna hrana.

V opačnom prípade, ak graf tieto podmienky nespĺňa, hovoríme o **multigrafe**. Všetky ďalšie definície a topologické metriky sa v rámci tejto práce budú vzťahovať na jednoduché grafy [23].

Okrem uvedeného rozdelenia môžeme grafy klasifikovať aj podľa ďalších vlastností, napríklad podľa prítomnosti váh na hranách. Na základe toho rozlišujeme graf na [6]:

- **ohodnotený**, ak každej hrane priraduje určité číslo (váhu), ktorá môže predstavovať cenu, vzdialenosť, alebo inú metriku v závislosti od kontextu,
- **neohodnotený**, ak váhy nepoužíva a sleduje len samotnú existenciu hrany.

Dôležité je aj spomenúť a definovať vzťahy a vlastnosti, ktoré vznikli pri vzájomnom prepojení jednotlivých prvkov grafu. Niektoré z týchto pojmov lepšie opisujú vnútornú organizáciu grafu alebo tvoria základ na výpočet topologických metrík. Zároveň nám umožňujú charakterizovať ďalšie špecifické typy grafov. Nasledujúce definície a teoretické poznatky sú čerpané z publikácií [33, 6, 23]:

- Vrchol je **incidentný** s hranou vtedy, ak hrana z tohto vrcholu vychádza alebo do neho vchádza.
- Vrcholy v_1 a v_2 sú **susedné**, ak existuje hrana, ktorá ich spája.
- Hrany e_1 a e_2 sú **susedné**, ak majú jeden spoločný vrchol.
- **Úplný graf** je graf, v ktorom sú všetky vrcholy susedné.
- **Cesta** je postupnosť vrcholov $v_0, v_1, \dots, v_n$, kde pre každé $i \in \{0, \dots, n-1\}$ existuje hrana medzi vrcholmi v_i a v_{i+1} , pričom platí, že všetky vrcholy sú navzájom rôzne.
- **Súvislý graf** je neorientovaný graf, v ktorom medzi každou dvojicou vrcholov existuje cesta.
- $G' = (V', E')$ je **podgraf** grafu $G = (V, E)$, ak platí, že $V' \subseteq V$ a zároveň $E' \subseteq E$ [3].
- **Komponent** grafu G je maximálny súvislý podgraf G . Pod pojmom maximálny chápeme, že daný podgraf už nie je možné rozšíriť o ďalší vrchol bez porušenia podmienky súvislosti. Preto graf G môže obsahovať viacero komponentov.

- **Regulárny graf** má rovnaký konkrétny stupeň k pre všetky vrcholy (stupeň vysvetlíme nižšie v 1.1.2).

1.1.2 Topologické metriky

Analýza vlastností grafu sa opiera o rôzne metriky, ktoré umožňujú opísať štruktúru prepojení. Niektoré z týchto metrík sú **lokálne**, zamerané na vlastnosti jednotlivých vrcholov, a **globálne**, ktoré opisujú graf ako celok. Pre zjednodušenie budeme v nasledujúcich vzorcoch pracovať s týmito základnými parametrami:

n – celkový počet vrcholov grafu, kde $n = |V|$,

e – celkový počet hrán grafu, kde $e = |E|$.

Vzdialenosť

Vzdialenosť medzi dvoma vrcholmi $u, v \in V$ opisuje dĺžku najkratšej cesty v grafe G , ktorá tieto vrcholy spája a označujeme ju $d(u, v)$ [6]. Pod pojmom najkratšia cesta rozumieme takú postupnosť hrán spájajúcu vrcholy u a v , ktorej celková dĺžka je minimálna možná. Ak medzi dvoma uzlami existuje viacero rôznych ciest, vzdialenosť určuje práve tá, ktorá prekonáva najmenší počet spojení, takže táto vzdialenosť je určená minimálnym počtom hrán. Ak neexistuje žiadna cesta medzi vrcholmi u a v , určuje sa ako $d(u, v) = \infty$.

Priemerná dĺžka najkratšej cesty

Táto metrika je v podstate priemerná vzdialenosť v grafe a predstavuje aritmetický priemer všetkých najkratších ciest medzi všetkými dvojicami vrcholov u, v v grafe.

Vzťah pre jej výpočet sa líši podľa typu grafu [2]:

- pre neorientované grafy:

$$\langle d \rangle = \frac{1}{\binom{n}{2}} \sum_{\substack{u, v \in V \\ u \neq v}} d(u, v) = \frac{2}{n(n-1)} \sum_{\substack{u, v \in V \\ u \neq v}} d(u, v), \quad (1.1)$$

- pre orientované grafy:

$$\langle d \rangle = \frac{1}{2\binom{n}{2}} \sum_{\substack{u, v \in V \\ u \neq v}} d(u, v) = \frac{1}{n(n-1)} \sum_{\substack{u, v \in V \\ u \neq v}} d(u, v), \quad (1.2)$$

kde $d(u, v)$ je už spomínaná najkratšia vzdialenosť medzi uzlami u a v .

Stupeň vrcholu

Stupeň k_v uzla v vyjadruje počet hrán incidentných tomuto uzlu [2]. V prípade orientovaných grafov rozlišujeme vstupný stupeň k_v^{in} , ktorý zodpovedá počtu hrán vchádzajúcich do uzla, a výstupný stupeň k_v^{out} pre hrany z uzla vychádzajúce. Celkový stupeň je potom definovaný ako ich súčet, teda $k_v^{\text{in}} + k_v^{\text{out}} = k_v$.

Priemerný stupeň

Priemerný stupeň grafu G je globálna vlastnosť, ktorá sa udáva nasledovne [2]:

$$\langle k \rangle = \frac{1}{n} \sum_{v \in V} k_v, \quad (1.3)$$

kde k_v je stupeň uzla v .

Distribúcia stupňov

Distribúcia stupňov vrcholov je pravdepodobnostné rozdelenie stupňov vrcholov, ktoré udáva pravdepodobnosť, že náhodne zvolený vrchol má stupeň k .

Definuje sa ako [2]:

$$P(k) = \frac{x_k}{n}, \quad (1.4)$$

kde x_k je počet vrcholov s daným stupňom k . Keďže je to pravdepodobnostná distribučná funkcia, spĺňa:

$$\sum_{k=1}^{k_{\max}} P(k) = 1.$$

Hustota

Hustota grafu je ukazovateľ miery prepojenosti vrcholov v grafe, teda udáva nakoľko je graf zaplnený hranami v porovnaní s grafom, v ktorom by medzi každou dvojicou vrcholov existovala hrana nad rovnakou množinou vrcholov. Čím viac hrán graf obsahuje, tým je hustota väčšia a jej hodnota sa pohybuje v intervale od 0 po 1.

Vzorec na výpočet podľa typu grafu [37]:

- pre neorientované grafy:

$$\rho(G) = \frac{e}{\binom{n}{2}} = \frac{2e}{n(n-1)}, \quad (1.5)$$

- pre orientované grafy:

$$\rho(G) = \frac{e}{2\binom{n}{2}} = \frac{e}{n(n-1)}. \quad (1.6)$$

Koeficient zhľukovania

Kľusterizácia, alebo zhľukovanie, je proces, ktorý v teórii grafov rozdeľuje graf na menšie, hustejšie prepojené podgrafy, tzv. kľastre. Tvorba kľastrov sa formuje na základe prepojenosti susedov jednotlivých vrcholov [30].

Koeficient zhľukovania, tiež nazývaný kľasterizačný koeficient, je metrika, ktorá vyjadruje do akej miery majú susedia vrcholu v tendenciu byť navzájom prepojení. V tomto prípade ide o lokálnu vlastnosť grafu, keďže sa počíta pre jeden konkrétny vrchol v [2, 23]. Tento koeficient meria hustotu podgrafu vytvoreného susedmi vrcholu, teda pomer počtu hrán medzi susedmi a maximálneho počtu hrán medzi nimi.

Definícia pre:

- neorientované grafy [23]:

$$C_v = \frac{e_v}{\binom{k_v}{2}} = \frac{2e_v}{k_v(k_v - 1)}, \quad (1.7)$$

- orientované grafy [8]:

$$C_v = \frac{e_v}{2\binom{k_v}{2}} = \frac{e_v}{k_v(k_v - 1)}, \quad (1.8)$$

pričom e_v je počet hrán medzi susedmi vrcholu v a k_v je stupeň vrcholu v , teda aj počet jeho susedov.

Pre získanie globálnej informácie o miere zhľukovania v celom grafe G sa používa priemerný koeficient zhľukovania, označujeme ho C .

Jeho výpočet sa zapisuje takto [23]:

$$C = \frac{1}{n} \sum_{v \in V} C_v. \quad (1.9)$$

1.2 Matematická lingvistiká

Jazyk možno chápať ako komplexný a systematický súbor znakov a pravidiel, ktorý slúži na komunikáciu a sprostredkovanie informácií medzi ľuďmi. Ide o štruktúrovaný systém, ktorý možno analyzovať na viacerých vzájomne prepojených rovinách, najmä zvukovej, gramatickej a významovej, ktoré sa riadia určitými princípmi. Na svete existuje mnoho jazykov, ktoré sa od seba výrazne líšia svojou štruktúrou a pravidlami, pričom niektoré z nich môžu prejavovať podobnosti v určitých rovinách, no ani v takých prípadoch nebudú úplne identické [21, 17].

Vednou disciplínou zaoberajúcou sa skúmaním jazyka je **lingvistika**. Zameriava sa nielen na štruktúru jazyka, ale aj na jeho funkcie, vývin a použitie v rôznych kontextoch. Jazyk je možné študovať a analyzovať z rôznych uhlov pohľadu, čo sa odráža aj v rozličných spôsoboch členenia lingvistiky [17]. Lingvistiku môžeme klasifikovať podľa viacerých kritérií: podľa sledovaného aspektu jazyka, metodologického zamerania alebo podľa jej prepojenia s inými vednými odbormi [27].

Podľa aspektu jazyka rozlišujeme analýzu jeho formy (fonológia, morfológia, syntax), významu (sémantika, pragmatika) alebo kontextu, ktorý zahŕňa vplyv sociálnych a historických vplyvov. Podľa metodologického zamerania členíme na deskriptívnu, historickú a komparatívnu lingvistiku. Využívaním poznatkov z iných vedných odborov vznikajú v lingvistike rôzne disciplíny, napríklad sociolingvistika (spojenie so sociológiou), neurolingvistika (zviazaná s neurológiou), matematickú lingvistiku a mnoho ďalších [27].

Podrobnejšie sa budeme venovať matematickej lingvistike.

Matematická lingvistika predstavuje odbor, ktorý spája lingvistiku s matematikou a informatikou. Jej hlavnou úlohou je skúmanie jazykových javov použitím matematických metód. Prienik týchto rozdielnych disciplín otvára kľúčovú otázku: či a akým spôsobom je možné popísať tak zložitý systém, akým je prirodzený jazyk, pomocou matematiky [32].

Odpoveď sa dá nájsť v samotnej povahe jazyka. Jazyk totiž nie je náhodné usporiadanie znakov, ale predstavuje komplexný „multidimenzionálny“ fenomén, v ktorom sú všetky jeho črty a znaky štrukturované a vzájomne prepojené. Môže sa to celé zdať nepredvídateľné, no pravdou je, že lingvistické znalosti, ktoré sa dajú opísať matematicky, majú stochastickú povahu. To znamená, že tieto znalosti neopisujú náhodné prípady, ale predpovedajú pravdepodobnosť výskytu daných javov v rámci celého systému jazyka. Táto systémová pravidelnosť a štatistiky umožňujú merať a modelovať jazyk ako systém [35].

Na základe použitých metód a cieľov výskumu matematickú lingvistiku tradične delíme na tri hlavné oblasti: **kvantitatívnu**, **algebraickú** a **počítačovú** lingvistiku [32].

1.2.1 Kvantitatívna lingvistika

Kvantitatívna lingvistika, označovaná aj ako štatistická lingvistika, používa na štúdium jazyka kvantitatívne matematické nástroje, predstavujúce štatistické a pravdepodobnostné metódy. Zameriava sa na opis jazyka založený na meraní a počítaní jazykových javov vo všetkých rovinách – od fonémov a grafémov, cez gramatické kategórie, až po štruktúry ucelených textov [32, 35].

Základným predpokladom pre matematickú analýzu v kvantitatívnej lingvistike je skutočnosť, že každý jazykový jav či znak, má v texte nejakú frekvenciu (početnosť). Táto frekvencia javov sa môže zdať ako náhodný proces, no je dokázané, že v dostatočne veľkých súboroch dát sa prejavujú určité štatistické pravidelnosti a tendencie. Je dôležité dodať, že tieto pravidelnosti majú zákonitý charakter [35].

Neobmedzuje sa však len na zaznamenávanie frekvencií a vytváranie zoznamov slov. Jej metódy umožňujú odhaliť hlbšie vlastnosti jazyka a ich vzťahy, ktoré nie sú hneď očividné. Ak vieme, ako často sa určité javy jazyka vyskytujú, dokážeme pochopiť aj ich kauzalitu a fungovanie. Štúdium kvantitatívnych aspektov jazyka pomáha porozumieť jeho kvalitatívnym charakteristikám, opisujúce druhy, typy a kategórie daného javu [32, 35].

Cieľom kvantitatívnej lingvistiky je aj pomocou univerzálnych zákonov vysvetliť, prečo jazykový systém nadobúda práve takúto podobu. Pozornosť sa teda nesústreďuje len na jazykové javy, ale predovšetkým na odhalenie hlbších príčin ich vzniku, usporiadania a fungovania [18]. Za najznámejšie kvantitatívne zákonitosti sa považujú Zipfove zákony a taktiež aj Heapsov zákon.

Prvý Zipfov zákon

Vyjadruje vzťah medzi frekvenciou slova a jeho poradím v klesajúcom zozname frekvencií, ktorých súčin je konštantný [35]:

$$f \cdot r = k_1, \quad (1.10)$$

kde f je frekvencia slova, r je poradie daného slova v zozname a k_1 je konštanta. Ďalej budeme využívať a spomínať hlavne tento prvý zákon, ktorý nadobúda aj podobu mocninového vzťahu a možno ho zapísať nasledovne:

$$f(r) \propto \frac{1}{r^\alpha} = r^{-\alpha}, \quad (1.11)$$

ktorý hovorí, že absolútna frekvencia $f(r)$ (počet výskytov slova) je nepriamo úmerná jeho poradiu r umocnenému na exponent α , ktorý nazývame Zipfov exponent. V ideálnom prípade sa predpokladá hodnota $\alpha = 1$, v reálnych textoch sa pohybuje v rozmedzí 0,7 až 1,2 [9].

Druhý Zipfov zákon

Formuluje vzťah medzi frekvenciou slova a počtom rôznych slov, ktoré majú rovnakú frekvenciu. Ukazuje, že počet slov s vysokou frekvenciou je malý a slov s klesajúcou frekvenciou je viac a viac [35]:

$$f^2 \cdot n = k_2, \quad (1.12)$$

kde f je frekvencia slova, n je počet rôznych slov s rovnakou frekvenciou a k_2 je konštanta.

Tretí Zipfov zákon

Vyjadruje vzťah medzi frekvenciou slova a počtom jeho významov. Slová s vyššou frekvenciou by mali mať väčší počet významov [35]:

$$\frac{m}{\sqrt{f}} = k_3, \quad (1.13)$$

kde f je frekvencia slova, m je počet významov a k_3 je konštanta.

Heapsov zákon

Heapsov zákon, označovaný aj ako Herdanov zákon, je štatistické pravidlo, ktoré popisuje, ako veľkosť slovnej zásoby rastie v závislosti od celkovej dĺžky textu.

Zápis mocninovým vzťahom [9]:

$$V(L) \propto L^\beta, \quad (1.14)$$

kde $V(L)$ predstavuje slovnú zásobu (od anglického slova *vocabulary*) a L je dĺžka textu (od *length*). Slovná zásoba je v tomto kontexte definovaná ako počet unikátnych slovných foriem. To znamená, že každé slovo sa výsledného súčtu započíta iba raz, bez ohľadu na to, koľkokrát sa v celom texte reálne vyskytuje. Naopak, dĺžka textu predstavuje celkový počet všetkých slovných výskytov, tiež zarátaných iba raz pre každé slovo. Exponent β je typicky v rozmedzí $0 < \beta < 1$ [9]. Tento exponent súvisí s tým, že na začiatku textu pribúdajú nové slová rýchlo, postupne sa to spomaľuje, preto má krivka sublineárny rast.

Heapsov zákon úzko súvisí so Zipfovým zákonom. Heapsov zákon možno chápať ako dôsledok vyplývajúci zo Zipfovho zákona. Ak frekvencie slov v texte sledujú mocninový zákon, potom aj počet rôznych slov rastie pomalšie než lineárne. Inak povedané, spôsob, akým sa slová v texte opakujú, ovplyvňuje aj to, ako rýchlo pribúdajú nové slová. Medzi exponentmi oboch zákonov pritom existuje približný vzťah. Ak Zipfov zákon má exponent α a Heapsov zákon exponent β , potom platí [9]:

$$\beta \approx \frac{1}{\alpha}. \quad (1.15)$$

Tento vzťah platí len pre veľmi dlhé texty. Pre reálne, konečné texty môže dôjsť k odchýlkam a Heapsov exponent nemusí presne zodpovedať prevrátenej hodnote Zipfovho exponentu. Odchýlky vznikajú najmä pri kratších textoch a závisia aj od samotnej dĺžky textu [9, 22].

1.2.2 Algebraická lingvistika

Algebraická lingvistika, označovaná aj formálna, predstavuje na rozdiel od kvantitatívnej lingvistiky smer nekvantitatívny. Zameriava sa najmä na formálny opis gramatík

a jazyka pomocou matematických a logických prostriedkov, pričom modeluje statické štruktúrne vlastnosti lingvistického systému. Využíva teóriu grafov, algebru, matematickú logiku a teóriu množín [32].

1.2.3 Počítačová lingvistika

Počítačová lingvistika sa môže označovať ako počítačová a predstavuje praktickú aplikáciu poznatkov z kvantitatívnej a algebraickej lingvistiky, a preto sa definuje aj ako aplikovaná matematická lingvistika. Má za úlohu počítačové spracovanie jazyka, po anglicky NLP – Natural Language Processing. NLP obsahuje algoritmy určené na spracovanie prirodzeného jazyka, zahŕňajúce strojový preklad, automatizovaný rozbor textu, uchovávanie a vyhľadávanie informácií, tvorbu gramatických korektorov (mechanizmov na detekciu a úpravu textov). Súčasťou počítačovej lingvistiky je aj korpusová lingvistika, ktorá skúma jazyk pomocou rozsiahlych súborov jazykových dát - korpusov, uchovávaných elektronicky [32].

1.3 Siete

Základy teórie grafov, ktorá poskytuje presný matematický jazyk na opis množín objektov a vzťahov medzi nimi, sme definovali už skôr. V tejto podkapitole sa presúvame od abstraktnej roviny k aplikáciám. Budeme používať pojem sieť ako reprezentáciu reálnych systémov, ktorých štruktúra je tvorená veľkým množstvom vzájomne prepojených prvkov. Táto podkapitola vychádza z publikácie autora Albert-László Barabási v [2].

Sieť je veľký graf, teda množina vrcholov a hrán medzi nimi. V niektorých literatúrach sa pojmy sieť a graf používajú zameniteľne, no vo vedeckej praxi medzi nimi existuje rozdiel, ktorý nespočíva v definícii, ale v interpretácii. Graf je abstraktný matematický objekt, zatiaľ čo sieť predstavuje model systému z reálneho sveta, ktorý využíva grafovú reprezentáciu. Vrcholy predstavujú entity, napr. ľudí, zariadenia, gény, a hrany vyjadrujú interakcie medzi nimi [2].

1.3.1 Reálne siete

Reálne siete predstavujú modely systémov, ktoré sa vyskytujú v skutočnom každodennom živote. Takéto siete majú uplatnenie v rôznych oblastiach, najmä v biológii, spoločnosti, technológiách či ekonomike. [2] V biológii ide napríklad o metabolické siete opisujúce interakcie medzi génmi, proteínmi a metabolitmi, alebo neurónové siete zobrazujúce prepojenia medzi neurónmi v mozgu. V spoločnosti sa využívajú na opis vzťahov medzi jednotlivcami, ako sú priateľstvá, rodinné či pracovné väzby. V ob-

lasti technológií patrí medzi najvýznamnejšie príklady internet a najmä sieť WWW (*World Wide Web*), kde vrcholy predstavujú webové stránky a hrany hypertextové odkazy medzi nimi. V energetike ide o elektrické rozvodné siete tvorené generátormi a prenosovými linkami. V ekonomike zohrávajú dôležitú úlohu obchodné siete, ktoré zabezpečujú výmenu tovarov a služieb a ovplyvňujú globálnu ekonomiku.

Reálne systémy, ktoré modelujeme pomocou sietí, sú typicky komplexné systémy, pretože sú zložené z obrovského množstva častí, príkladom je ľudský mozog s miliardami neurónov, spoločnosť s miliardami jednotlivcov, alebo internet s miliardami zariadení. Dôvodom ich komplexity nie je len počet komponentov, ale hlavne spôsob, akým sú tieto komponenty navzájom prepojené a ako medzi sebou interagujú. Táto vzájomná spojitosť vytvára vysokú mieru prepojenosti, ktorá spôsobuje, že zmeny alebo poruchy v jednej časti sa môžu šíriť ďalej do ďalších častí, čo môže viesť ku kaskádovým zlyhaniam, kedy lokálny problém vyvolá narušenie celého systému [2].

V kontraste s reálnymi sieťami sú **náhodné siete**, ktoré sa v skutočných systémoch prakticky nevyskytujú, keďže reálne siete nie sú vytvorené náhodne a vyznačujú sa určitými štrukturálnymi vlastnosťami. V tejto práci sa im nebudeme venovať detailne, v teórii sietí však predstavujú základný model na porovnávanie. Slúžia ako referenčný model, ktorý umožňuje určiť, či sú určité vlastnosti reálnych sietí výsledkom náhody, alebo dôsledkom ich štruktúry [2].

Aby sme porozumeli, ako komplexné systémy fungujú, je potrebné získať informácie aj o štruktúre ich sietí a ich topológii, ktoré sú kľúčové pre správanie celého systému. Bez poznania tejto štruktúry nie je možné plne pochopiť, ako tieto systémy fungujú. Analýza sietí tak umožňuje odhaliť základné organizačné princípy, ktoré sú spoločné pre rôzne typy reálnych systémov.

1.3.2 Vlastnosti reálnych sietí

Ako sme uviedli v predchádzajúcej časti, reálne systémy, ktoré modelujeme pomocou sietí, majú špecifické štrukturálne charakteristiky. Ak by sme tieto systémy opísali náhodným grafom, ich správanie by sa výrazne líšilo. Tieto charakteristiky majú zásadný vplyv na fungovanie systémov, ktoré siete reprezentujú, a preto je potrebné ich bližšie preskúmať.

Nízka hustota

V reálnych sieťach platí, že tieto siete majú nízku hustotu. Aj napriek veľkému počtu uzlov je príznačné, že počet prepojení e v sieti je v porovnaní s maximálnym možným počtom hrán e_{max} vždy výrazne menší, teda $e < e_{max}$. Z toho vyplýva, že sieť reálneho systému nikdy nebude tvoriť úplnú sieť (t.j. úplný graf, pozri časť 1.1.1) a ich hustota (viď vzorce 1.5 a 1.6) bude menšia ako 1 [2].

Bezškálovosť

Vyššie sme už vysvetlili distribúciu stupňov (viď 1.1.2), ktorý umožňuje kvantitatívne opísať štruktúru sietí. Práve distribúcia stupňov sa využíva na vysvetlenie javu, ktorý nazývame bezškálovosť. Albert-László Barabási, autor knihy, z ktorej čerpáme, zistil pri analýze rozsiahlych reálnych sietí, že distribúcia stupňov týchto sietí sa riadi mocninovým zákonom [2]:

$$p_k \sim k^{-\gamma}, \quad (1.16)$$

kde p_k je pravdepodobnosť, že náhodne zvolený uzol má práve k spojení a γ je exponent mocninového zákona, označovaný ako škálovací exponent [23]. Pre väčšinu reálnych sietí sa hodnota exponentu pohybuje v rozmedzí $2 < \gamma < 3$. Ak zlogaritmujeme 1.16, získame [2]:

$$\log p_k \sim -\gamma \log k, \quad (1.17)$$

pričom platí, že $\log p_k$ lineárne závisí od $\log k$ a sklon tejto priamky je $-\gamma$. Toto vyjadrenie sa týka neorientovaných reálnych sietí, ale ak by sa jednalo o orientované, skonštruuje sa distribúcia stupňov pre k_{in} a k_{out} , čím vzniknú aj dva škálovacie exponenty. Ak by sme vyjadrovali distribúciu stupňov pre náhodné siete, jej tvar by bol odlišný. Získali by sme Poissonovo rozdelenie.

Teraz sa dostávame priamo k definícii našej opisovanej vlastnosti. Siete, ktorých distribúcia stupňov nasleduje mocninový zákon, sa nazývajú bezškálové siete. Znamená to, že v takýchto systémoch chýba charakteristická vnútorná škála. V náhodných sieťach má väčšina uzlov stupeň sústredený okolo priemeru $\langle k \rangle$, ktorý slúži ako mierka siete. V reálnych sieťach má väčšina uzlov výrazne nízky stupeň, zatiaľ čo niekoľko uzlov ho má extrémne vysoký. Siete s touto vlastnosťou označujeme ako siete bez škály [2].

Uzol, ktorý má výnimočne vysoký stupeň, nazývame **hub**. Huby sú priamym dôsledkom mocninového rozdelenia. Držia sieť pohromade a vytvárajú prepojenia medzi veľkým množstvom uzlov s malým stupňom. Veľkosť najväčšieho hubu rastie s veľkosťou siete a to znamená, že čím je sieť väčšia, tým väčšie huby sa v nej budú nachádzať. Dôležitým rozdielom oproti náhodným sieťam je, že v nich sú huby prakticky zakázané – nenašli by sme ich a v reálnych bezškálových sieťach sú naopak očakávanou súčasťou. Táto vlastnosť súvisí s prítomnosťou tzv. „fat-tailed” distribúcie, čo znamená, že chvost mocninového zákona (oblasť uzlov s vysokými hodnotami stupňa k) klesá výrazne pomalšie než pri exponenciálnom rozdelení [2].

Distribúcia stupňov s mocninovým zákonom a Zipfov zákon (viď 1.2.1) sa správajú podobne. V oboch prípadoch platí, že veľké hodnoty sa vyskytujú zriedkavo a malé často. Ide o dva príbuzné spôsoby opisu škálového rozdelenia a práve preto medzi Zipfovým exponentom α a škálovacím exponentom γ mocninového zákona existuje

určitý vzťah [22].

Vieme ho zapísať takto [22]:

$$\alpha = \frac{1}{\gamma - 1} \quad \text{resp.} \quad \gamma = 1 + \frac{1}{\alpha}. \quad (1.18)$$

Teória malého sveta

Koncept malého sveta vychádza z otázky sociálnej psychológie: Aká je pravdepodobnosť, že dvaja náhodne vybraní ľudia na svete sa budú navzájom poznať? Následne vznikla nadväzujúca otázka: Aký dlhý je reťazec známostí, ktorý by spájaj týchto dvoch ľudí? [25]

Experimentálne tento problém prvýkrát skúmal psychológ Stanley Milgram v roku 1967. Zistil, že dĺžka reťazca známostí medzi dvoma ľuďmi sa pohybovala približne od 2 do 10 medzičlánkov, pričom medián bol 5. Na základe týchto výsledkov vznikol koncept „šiestich stupňov odlúčenia”, ktorý hovorí o tom, že akýchkoľvek dvoch ľudí na planéte delí v priemere len päť sprostredkovateľov, čo znamená šesť prepojení. Nejde o pevné stanovené maximum, ale o priemernú hodnotu [25].

V roku 1998 sformovali tento sociologický fenomén do matematickej podoby matematici Duncan J. Watts a Steven H. Strogatz. Navrhli tzv. Watts-Strogatz model, ktorý umožňuje opis a analýzu sietí s vlastnosťami malého sveta. Vysvetlili, že sa reálne siete nachádzajú niekde medzi regulárnymi (t.j. regulárnymi grafmi, pozri 1.1.1) a náhodnými sieťami. Zistili, že tieto siete kombinujú ich vlastností - majú nízku priemernú dĺžku najkratších ciest, rovnako ako náhodné grafy, a zároveň vysoký koeficient zhľukovania, typický pre pravidelné siete. Zistili tiež, že na vznik siete malého sveta stačí nahradiť malý počet väzieb náhodnými „skratkami”, čo dramaticky zníži priemernú vzdialenosť medzi uzlami. To vysvetľuje vysokú efektivitu šírenia v reálnych systémoch [38].

S príchodom bezškálových sietí sa koncept malého sveta ďalej rozvinul. Barabási zistil, že v bezškálových sieťach s exponentom $2 < \gamma < 3$ sú priemerné vzdialenosti medzi uzlami ešte kratšie než v klasických malých svetoch [2]. Tento jav nazývame ultra-malý svet, kde výraznú úlohu v týchto vzdialenostiach zohrávajú huby.

Vysoká miera zhľukovania

Jednou z hlavných vlastností reálnych sietí je vysoká hodnota klasterizačného koeficientu. Túto vlastnosť sme už okrajovo spomenuli v porovnaní s náhodnými sieťami. Vysoká miera zhľukovania znamená, že uzly majú tendenciu vytvárať husté lokálne skupiny (podrobné vysvetlenie v podkapitole 1.1.2). Kým v náhodných sieťach klesá koeficient zhľukovania nepriamo úmerne s veľkosťou siete ($C \sim 1/n$), v reálnych sieťach je zvyčajne výrazne vyšší a má len slabú závislosť od počtu uzlov n [2].

Barabási vo svojom výskume zistil, že hodnoty tohto koeficientu sa výrazne líšia aj

v závislosti od typu siete [2]. Sociálne siete majú vysokú mieru, stokrát väčšiu ako v náhodnom modeli. Pomerne vysokou hodnotou disponujú aj biologické siete, no technologické siete, ako je internet, majú nízku mieru zhlukovania.

Ďalším dôležitým zistením bolo, že lokálny klasterizačný koeficient závisí od stupňa uzla k_v – s narastajúcim stupňom jeho hodnota klesá [2]. Uzly s nízkym stupňom, ktoré v sieti tvoria väčšinu, dosahujú spravidla vyššie hodnoty koeficientu zhlukovania. Naopak, pre huby je tento koeficient výrazne menší.

Korelácie stupňov

Distribúcia stupňov nie je jediným faktorom, ktorý určuje správanie siete. Rovnako dôležité je, aké uzly sa navzájom spájajú. Túto vlastnosť opisujú korelácie stupňov. Vysvetľujú, či majú uzly s určitým počtom väzieb tendenciu vyhľadávať partnerov s podobným počtom prepojení, alebo sa im vyhýbajú.

Na základe týchto korelácií rozlišujeme tri typy sietí [2]:

1. **Asortatívna sieť** sa vyznačuje tým, že huby sa spájajú s inými hubmi, zatiaľ čo uzly s nízkym stupňom sa spájajú s inými málo prepojenými uzlami. Tento typ je typický pre sociálne siete.
2. **Disasortatívna sieť** sa vyznačuje opačným správaním, keď sa huby vzájomne vyhýbajú a spájajú sa s uzlami s nízkym stupňom. Tento typ je typický pre biologické a technologické siete.
3. **Neutrálna sieť** neprejavuje žiadnu zvláštnu vlastnosť, pretože uzly sa spájajú s ďalšími uzlami bez ohľadu na ich stupeň.

1.3.3 Slovné siete


Ako už vieme, prirodzený jazyk považujeme za komplexný systém, v ktorom jednotlivé slová vstupujú do vzájomných vzťahov a umožňujú vytváranie nekonečného množstva viet z konečného súboru prvkov. Tieto vzťahy medzi slovami nie sú náhodné a vytvárajú organizáciu jazyka, ktorú je možné reprezentovať pomocou slovných sietí [4].

V takejto sieti každý uzol zodpovedá jednému slovu a hrany medzi uzlami reprezentujú určité vzťahy medzi dvojicami slov, napríklad ich spoluvýskyt vo vete alebo v konkrétnom kontexte. Tieto siete nám umožňujú skúmať vývoj jazyka, jeho vlastnosti, kľúčové slová, vzťahy medzi slovami a organizáciu jazyka. Z hľadiska teórie grafov sa slovná sieť definuje ako dvojica (W_L, E_L) , kde množina vrcholov W_L predstavuje unikátne lexikálne jednotky – slová a E_L je množina hrán znázorňujúca ich vzájomné interakcie [4].

V závislosti od definície interakcií medzi slovami môžeme slovné siete definovať napríklad ako sémantické a syntaktické [24].

Syntaktické siete, označované aj ako pozičné, odrážajú syntaktickú štruktúru jazyka a sú definované na základe spoluvýskytu slov v texte. Hrany teda spájajú slová, ktoré sú v rámci viet najbližšími susedmi [24]. Tieto siete sa môžu využívať ako prostriedok na skúmanie jazykovej poruchy afázie a jej foriem, agramatizmu a paragramatizmu [4].

Na obrázku 1.2 je znázornená štruktúra slovnej siete vytvorená z úvodných troch viet diela *Premena*. V texte boli pred procesom vizualizácie odstránené interpunkčné znamienka a všetky písmená boli prevedené na malé.



Obr. 1.2: Príklad syntactickej siete vytvorenej z úryvku diela *Premena* v slovenskom jazyku od *F. Kafku* v aplikácii Gephi. Smerovanie textu je v grafe naznačené farebnými indikátormi: zelená šípka označuje počiatočný bod úryvku a červená šípka jeho koniec.

Zameriavajú sa tiež na vzťahy určené gramatickými kategóriami a rolami slov, ktoré spolu susedia. Formalizujú závislostné väzby, ako napríklad vzťahy medzi podstatným a prídavným menom, slovesom a predmetom. Okrem gramatiky definujú aj ustálené výrazy a kolokácie, ktoré v rámci vety fungujú ako jedna spoločná jednotka [4].

Syntaktické siete boli častou výskumu od profesorov Ramona Ferrera i Cancha a Ricarda V. Solého. Zistili, že naozaj majú architektúru „malého sveta”, pričom analýza ukázala, že priemerná vzdialenosť medzi dvoma ľubovoľnými slovami je v anglickom texte v rozsahu len 2 až 3 hrany (resp. kroky v rámci cesty v grafe), čo umožňuje mozgu efektívne a plynulo generovať reč. Autori taktiež preukázali, že tieto siete sa vyznačujú bezškálovou distribúciou stupňov.

Syntaktické siete tak poskytujú vhodný nástroj na analýzu a následné porovnanie rôznych jazykových systémov pomocou sieťových metód.

Sémantické siete, ktoré nazývame aj koncepčné, popisujú vzťahy medzi slovami na základe významovej podobnosti alebo súvislosti konceptov [24, 26]. Hrany medzi slovami vznikajú napríklad v prípade synonymie, antonymie alebo hierarchických vzťahov (hyponymie) [11]. Využívajú sa napríklad v kognitívnej vede na modelovanie asociatívnej pamäte, v lingvistike na štúdium evolúcie jazykov (rovnako ako aj syntaktické) a v informačnom vyhľadávaní [11, 26].

Svojou architektúrou má sieť vlastnosti „malého sveta”, avšak z hľadiska bezškálovosti nejde o ideálne bezškálovú sieť v celom rozsahu hodnôt. Bezškálová sieť by mala mať rozdelenie stupňov, ktoré sa riadi mocninovým zákonom pre všetky hodnoty stupňa uzla, no v tomto prípade sa takéto správanie objavuje iba pre veľké hodnoty stupňa uzla [26].

1.4 Interpunkcia v analýze textu

Interpunkcia predstavuje kľúčový prvok písaného jazyka, ktorý napomáha zrozumiteľnosti, presnému významu a účinnému vyjadrovaniu. Skladá sa z rôznych symbolov a znamienok, ktoré slúžia na organizáciu a štruktúrovanie viet, pričom čitateľovi naznačujú pauzy, dôraz a vzťahy medzi slovami a myšlienkami [7, 1]. Význam interpunkcie v textovej analýze je kľúčový, pretože tieto znamienka nepredstavujú len formálnu súčasť textu, ale ovplyvňujú aj pravopis, morfológiu, syntaktické vzťahy, sémantickú informáciu, čím v konečnom dôsledku formujú celkovú textovú štruktúru [34].

Z hľadiska funkčného využitia možno interpunkčné znamienka rozdeliť na dve základné kategórie: gramatické a rétorické. Gramatické slúžia na vyznačenie hraníc medzi jednotlivými úsekmi textu a naznačujú, akým spôsobom majú byť tieto časti navzájom prepojené. Naopak, rétorické vyjadrujú dôraz alebo zvukovú stránku prejavu, ktorú chce autor priradiť konkrétnemu úseku [34].

Správne používanie interpunkcie je kľúčové pre odstránenie dvojznačnosti významu viet. Pomáha efektívnej komunikácii pri sprostredkovaní zamýšľanej správy a zabezpečujú, aby čitatelia interpretovali text tak, ako bolo zamýšľané [7, 1].

1.4.1 Štatistická povaha interpunkcie a jej význam v sieťach

Okrem všeobecných lingvistických funkcií má interpunkcia význam aj z hľadiska kvantitatívnej analýzy textu. Výskum Kuliga a kol. [19] ukazuje, že interpunkčné znamienka v textoch podliehajú rovnakej štatistike ako slová a zároveň majú podobné vlastnosti ako najčastejšie slová, napríklad členy, spojky, predložky a zámená.

Dôležitým zistením je ich vplyv na platnosť Zipfovho zákona. Aj keď bol pôvodne formulovaný pre distribúciu frekvencie slov, ukazuje sa, že mu podliehajú aj interpunkčné znamienka [19]. Podľa výskumu Kuliga, ich zahrnutie do analýzy navyše vedie k lepšiemu škálovaniu grafov závislosti frekvencie od poradia slov podľa ich frekvencie (od najčastejšieho po najmenej časté), a to najmä v oblasti najvyšších pozícií tohto poradia ($R < 10$). Štúdia taktiež ukazuje, že vo viacerých európskych jazykoch sa čiarka umiestňuje na prvom mieste ($R = 1$), nasledovaná bodkou ($R = 2$ alebo $R = 3$). Výnimočné postavenie majú aj otáznik a výkričník, ktoré sa zvyčajne pohybujú v rozmedzí $10 < R < 30$, zatiaľ čo bodkočiarka a dvojbodka dosahujú $10 < R < 50$. Táto zhoda je pozorovateľná naprieč germánskymi, románskymi a slovanskými jazykmi.

Pri vytváraní syntaktických slovných sietí sa každé slovo v texte stáva uzlom. Do tejto siete môžeme zahrnúť aj interpunkčné znamienka ako samostatné uzly, pretože majú v texte výraznú úlohu. Keďže majú veľmi vysokú frekvenciu, je očividné, že aj ich stupeň bude vysoký a preto sa stávajú hubmi. Ich odstránenie by zmenilo jej globálne vlastnosti, pretože tieto uzly fungujú ako kľúčové spojovacie prvky. Okrem toho, znamienka ako bodka a čiarka majú v porovnaní s bežnými slovami výrazne nižšiu priemernú najkratšiu vzdialenosť k ostatným uzlom a fungujú ako efektívne skratky a znižujú tak celkovú priemernú vzdialenosť v grafe [19].

Kapitola 2

Metodika a spracovanie dát

Táto kapitola popisuje praktický postup pri spracovaní textov, tvorbe slovných sietí a výpočte ich charakteristík. Najprv sú predstavené východiskové texty v šiestich jazykových verziách diela *Premena*. Následne je opísané pedspracovanie textov, teda ich úprava a čistenie v rámci jazykových špecifických zmien prispôbených jednotlivým jazykom. Ďalej sú vysvetlené nástroje a knižnice, ktoré boli použité pri automatizovanom spracovaní. V kapitole je tiež vysvetlený princíp tvorby slovných sietí a spôsob zostrojenia charakteristík

2.1 Východiskové texty

Pre účely tejto práce bola ako primárny zdroj dát zvolená novela *Premena* od svetoznámeho autora Franza Kafku z roku 1915 [36]. Hoci bol autor pražským rodákom, svoje diela písal v nemeckom jazyku. Dielo bolo zvolené pre svoje významné postavenie vo svetovej literatúre a pre jeho autora, ktorý patrí medzi všeobecne uznávané literárne osobnosti. Zároveň je dostupné v mnohých jazykových prekladoch, čo by malo zabezpečiť, že jeho sémantický obsah zostane zachovaný aj naprieč rôznymi verziami.

2.1.1 Zoznam použitých jazykových verzií a ich vlastnosti

V práci bolo do analýzy zaradených šesť jazykových verzií Kafkovej *Premeny*, ktoré reprezentujú dve hlavné jazykové rodiny - germánsku a románsku. Tieto rodiny síce zdieľajú spoločný pôvod v rámci indoeurópskej jazykovej rodiny, no vyvinuli si odlišné štruktúrne vlastnosti. Líšia sa nielen slovnou zásobou, ale aj syntaktickou štruktúrou (napr. slovosledom) a morfológickými vlastnosťami. Z pohľadu slovnej zásoby si románske jazyky zachovávajú dominantný latinský základ, zatiaľ čo germánske stavajú na pôvodných germánskych koreňoch. Z hľadiska slovosledu majú germánske jazyky pevnejšiu štruktúru – v nemčine je typické postavenie slovesa na druhom mieste a románske jazyky disponujú pružnejším slovosledom. Čo sa týka morfológie, nemčina si

na rozdiel od románskych jazykov zachovala pádový systém, no románske jazyky pádové koncovky stratili [29, 28]. Aj napriek spoločnému pôvodu jazykov v rámci jednej jazykovej rodiny nie sú tieto jazyky identické, čo sa prejavuje v ich štruktúrnych aj lexikálnych rozdieloch.

Vybrané jazykové verzie:

- **Germánske jazyky:**

- nemecká verzia - Die Verwandlung [16],
- anglická verzia - Metamorphosis [15],
- holandská verzia - De gedaanteverwisseling [14].

- **Románske jazyky:**

- španielska verzia - La Metamorfosis [13],
- talianska verzia - La Metamorfosi [10],
- portugalská verzia - A Metamorfose [12].

Vzhľadom na potrebu zabezpečenia vysokej kvality textu boli jednotlivé verzie diela *Premena* hľadané a čerpané z digitálnych knižníc a vedeckých archívov. Pri výbere sme kladli dôraz na to, aby texty neboli len neoverené a zle preložené prepisy, ale aby išlo o reálne verzie publikovaných vydání, nie vždy nevyhnutne knižných.

Nemecká a anglická forma diela boli čerpané z digitálnej knižnice Project Gutenberg (<https://www.gutenberg.org>), ktorá predstavuje online projekt zameraný na sprístupňovanie elektronických kníh. Španielsky a portugalský variant boli čerpané z akademického portálu Academia.edu (<https://www.academia.edu>), ktorý slúži ako platforma na zdieľanie výskumných prác a akademických textov. Holandská a talianska verzia boli získané z digitálneho archívu Internet Archive (<https://archive.org>), knižnice s rozsiahlou zbierkou digitalizovaných textov, kníh a iných formátov, pričom vybrané boli skeny knižných vydání, z ktorých bol text extrahovaný cez optické rozpoznávanie znakov (OCR).

Jazyk	Počet slov	Počet znakov
nemecký	19258	101774
anglický	22009	96367
holandský	21058	100228
španielsky	20844	100073
taliansky	18023	93569
portugalsky	17006	98406

Tabuľka 2.1: Základné štatistiky analyzovaných textov

Takto získané texty boli následne analyzované pre ich základné charakteristiky – celkový počet slov a znakov. Ich prehľad je poskytnutý v tabuľke 2.1. Z údajov môžeme vidieť, že napriek identickej sémantickej predlohe sa charakteristiky naprieč jazykmi líšia. Najvyšší počet slov má anglická verzia a naopak najnižší evidujeme v portugalskej. Na druhú stranu, počet znakov je najvyšší v nemčine a najnižší v taliančine. Tieto rozdiely sú spôsobené najmä morfológickými a syntaktickými vlastnosťami jednotlivých jazykov. Pre potreby tejto práce sú však všetky texty dostatočne rozsiahle.

2.2 Predspracovanie textu

Vzhľadom na to, že texty sú čerpané z rôznych zdrojov a jednotlivé jazyky nemajú rovnaké pravidlá používania interpunkcie alebo iných špecifických vlastností, nevyhnutným krokom bolo zjednotenie formátu a odstránenie prvkov, ktoré by mohli skresliť výsledky analýzy. Celý tento proces bol vykonaný manuálne s využitím vyhľadávacích funkcií textového editora.

Aby sme zabránili vzniku rôznych foriem pre konkrétnu interpunkciu a zbytočným uzlom v neskoršie vytvorených sieťach, všetky povolené interpunkčné znamienka budú zjednotené podľa tabuľky 2.2.

Interpunkcia	Znamienko
bodka	.
čiarka	,
otáznik	?
výkričník	!
bodkočiarka	;
dvojbodka	:
pomlčka (spojovník)	-
úvodzovky	"
ľavá zátvorka	(
pravá zátvorka	)
tri bodky	...

Tabuľka 2.2: Zoznam interpunkčných znamienok zachovaných ako samostatné uzly

Do analýzy neboli zahrnuté časti, ktoré nie sú súčasťou textu diela, teda názov, úvodné a záverečné časti textov, čísla strán, kapitoly, predhovory a ani žiadne nežiaduce informácie. Zachované boli iba samotné vety ako súvislý text. Pri textoch po procese OCR v prípade zistenia zjavných chýb boli tieto chyby manuálne opravené podľa fyzickej predlohy.

Súčasťou tohto predspracovania bolo aj ošetrovanie skrátených tvarov, slov spojených apostrofom a zlúčených slovných spojení, aby sa neskôr pri tvorbe slovných sietí minimalizovali unikátne slová. Dôležité bolo zabezpečiť, aby proces čistenia neporušil gramatickú správnosť slov a textu a zároveň umožnil korektnú identifikáciu slovných tvarov.

Vzhľadom na odlišnosť všetkých vybraných jazykov nebolo možné aplikovať univerzálny postup čistenia na všetky verzie súčasne. Každý jazyk si vyžadoval špecifický prístup k odstráneniu prvkov, ktoré by v sieti pôsobili ako šum. Nasledujúce body popisujú konkrétne zmeny v jednotlivých textoch.

Nemecký text

V nemčine boli ošetrované zlúčené tvary vzniknuté spojením predložky s členom, ako napríklad *im* (in dem), *am* (an dem), *zum* (zu dem) či *zur* (zu der). Z hľadiska typografie boli dvojité pomlčky (--) nahradené unifikovanou pomlčkou (-) a nemecké úvodzovky (« a ») boli zjednotené na štandardný znak (").

Anglický text

Skrátené tvary, ako napríklad *don't* (do not), *can't* (cannot) a mnoho ďalších, boli rozšírené na plné tvary, no pri tvaroch s nejednoznačným významom, ako *he'd* (he would alebo had) a iné, bol zisťovaný kontext a následne rozšírený. Zložené slová tvorené spojovníkom boli oddelené medzerou na dve rôzne slová. Pri privlastňovacích tvaroch v singulári (napr. *Gregor's*) bolo privlastňovanie vymazané a v pluráli (napr. *parents'*) bol vymazaný iba apostrof.

Španielsky text

V rámci španielskej verzie boli odstránené počiatočné interpunkčné znamienka *¿* a *¡*, pretože v ostatných jazykoch sa takéto znaky nevyskytujú. Úvodzovky monológu (« a ») a úvodzovky priamej reči (–) boli nahradené dohodnutými úvodzovkami (") a tam, kde chýbala druhá úvodzovka na ukončenie priamej reči, bola doplnená.

Holandský text

V holandčine boli holandské úvodzovky (') tiež unifikované ("). Skrátené tvary ako *zo'n* (zo een), *'m* (hem) a *z'n* (zijn) boli rozšírené na plné tvary. V texte sa nachádzali aj *'s*, čo predstavujú tvary genitívu, ktoré sa nedajú rozšíriť, takže apostrof bol vymazaný.

Portugalský text

Zvratné slovesá spojené pomlčkou (napr. *dirigiu-se*) boli oddelené na dve slová. Priama reč vytváraná len jednou (-) bola nahradená štandardnými úvodzovkami (") a taktiež bola pridaná aj druhá na ukončenie reči. Zvyšné pomlčky predstavovali slovesá

spojené pomocou pomlčky so zámenom (napr. *apalpa-lo*, čo je spojenie slovesa *apalpar* a zámena *o*) boli rozdelené na dve samostatné slová, keďže nie je gramaticky správne ich rozširovať.

Taliansky text

Talianske úvodzovky (« a ») boli vymenené za štandardné ("). Skrátené tvary vzniknuté elíziou (napr. *po'* za *poco*, ako aj tvary *so s'*, *m'*, *c'*, *v'*, *ch'* za *sí*, *mi*, *ci*, *vi*, *che*) boli rozšírené na plné tvary. Zvyšné slová s apostrofom predstavujú povinné elízie talianskej gramatiky, ktoré nie je možné rozšíriť, a preto boli rozdelené na dve samostatné slová oddelené medzerou.

2.3 Tvorba slovných sietí a výpočet charakteristík

Po procese predspracovania boli jednotlivé texty pripravené na transformáciu do podoby slovných sietí. V tejto časti je popísaný postup ich konštrukcie, použité nástroje a spôsob výpočtu vybraných sieťových charakteristík. Cieľom je vytvoriť modely umožňujúce analyzovať štruktúru textu a porovnať vplyv rôznych faktorov, ako je interpunkcia alebo lematizácia. V nasledujúcich odsekoch sú stručne predstavené tie knižnice, ktoré zohrali kľúčovú úlohu pri tvorbe sietí a ich vizualizácii výsledkov.

2.3.1 Použité nástroje a knižnice

Keďže manuálne spracovanie textov v šiestich jazykoch a vytváranie sietí by bolo časovo náročné, celý proces bol automatizovaný. V súčasnosti existuje množstvo nástrojov a možností, ktoré je možné na tento účel využiť. V tejto práci boli použité najmä knižnice a nástroje umožňujúce transformáciu textov do podoby slovných sietí, ich následnú analýzu a tvorbu grafov, a to jednotným spôsobom pre každý jazyk.

Celá tvorba sietí a ich analýza bola vytvorená v programovacom jazyku Python (<https://www.python.org>), ktorý bol zvolený najmä vďaka širokej ponuke knižníc na prácu s textom a grafmi, čo výrazne uľahčilo a urýchlilo spracovanie dát.

NetworkX

NetworkX (<https://networkx.org>) je knižnica určená na vytváranie, úpravu a analýzu komplexných sietí v Pythone. Umožňuje prácu s orientovanými aj neorientovanými grafmi, alebo ďalšími inými typmi grafov. Poskytuje rôzne analytické funkcie na výpočet základných sieťových metrík, napríklad stupňa uzlov, hustoty siete, priemernej dĺžky cesty či koeficientu zhľukovania.

SpaCy

SpaCy (<https://spacy.io/>) predstavuje knižnicu v Pythone, ktorá sa využíva na spracovanie a analýzu textu v úlohach spracovania prirodzeného jazyka (NLP). Ponúka predtrénované modely pre rôzne jazyky a medzi jej kľúčové funkcie patrí tokenizácia, lematizácia, rozpoznávanie slovných druhov a mnoho ďalších,

Tokenizácia je proces rozdelenia textu na menšie jednotky, ktoré nazývame tokeny. Token je definovaný ako postupnosť znakov, ktoré spolu tvoria jednotku. Môže ním byť slovo, ale aj interpunkčné znamienko či iný významový celok.

Lematizácia je proces zjednodušenia slov na ich základný tvar, nazývaný lema. Tento proces sa uplatňuje na slová vzniknuté skloňovaním, časovaním, skracovaním alebo spájaním.

Matplotlib

Matplotlib (<https://matplotlib.org/>) je knižnica pre Python určená na vizualizáciu dát vo forme matematických grafov. Umožňuje vytvárať čiarové alebo stĺpcové grafy, histogramy a ďalšie typy grafov. Služi na zobrazovanie číselných a štatistických údajov.

SciPy

SciPy (<https://scipy.org/>) je knižnica v jazyku Python, ktorá je určená na pokročilé technické a vedecké výpočty. Rozširuje v podstate inú knižnicu (NumPy) o moduly na optimalizáciu, štatistické metódy a pokročilejšiu matematiku. Z hľadiska analýzy dát je zaujímavý podmodul `scipy.stats`, ktorý obsahuje zbierku štatistických funkcií a rozdelení pravdepodobnosti.


Powerlaw

Powerlaw (<https://pypi.org/project/powerlaw/>) predstavuje knižnicu, ktorá sa využíva primárne na aproximáciu mocninového zákona z dát týkajúcich sa „fat-tailed” distribúcie, ako napríklad distribúcie stupňov uzlov v sieťach.

Gephi

Gephi (<https://gephi.org/>) je voľne dostupná aplikácia určená na vizualizáciu a analýzu grafov a rozsiahlych sietí. Na rozdiel od programovacích knižníc poskytuje grafické a interaktívne používateľské rozhranie (viď obrázok 2.1), ktoré umožňuje jednoduché prehliadanie komplexných sietí, filtrovanie uzlov a úpravu ich vizuálnej reprezentácie. Používateľ môže meniť farbu, veľkosť a tvar uzlov na základe rôznych kritérií, napríklad podľa stupňa uzla alebo iných štatistických vlastností. Súčasťou aplikácie sú aj rôzne algoritmy na rozloženie grafu, ktoré pomáhajú efektívne rozmiestniť uzly v

priestore tak, aby bola štruktúra siete prehľadnejšia. Gephi zároveň obsahuje vstavané nástroje na výpočet základných sieťových metrík.



Obr. 2.1: Ukážka Gephi rozhrania a vizualizácia slovnej siete

2.3.2 Princíp a postup tvorby slovnej siete

Po očistení textu v jednotlivých jazykoch nasledovala ich transformácia do podoby syntaktickej siete založenej na princípe susednosti slov v texte. Tento proces predstavuje prechod k štruktúrnemu chápaniu jazyka ako komplexného systému, v ktorom slová nie sú izolovanými jednotkami, ale prvkami navzájom prepojenými.

Pre účely tejto práce a porovnania štruktúry boli vytvorené viaceré verzie sietí, ktoré sa líšia v dvoch charakteristikách: v zahrnutí interpunkcie a použití lematizácie. Ich kombináciou vznikli pre každý jazyk štyri typy sietí zložené z:

- pôvodného textu bez interpunkcie,
- pôvodného textu so zahrnutím interpunkcie,
- lematizovaného textu bez interpunkcie,
- lematizovaného textu so zahrnutím interpunkcie.

Tento prístup umožňuje následne porovnať, ako jednotlivé faktory ovplyvňujú vlastnosti grafov. Postup tvorby bol nasledovný:


1. Prvým krokom tohto procesu bola tokenizácia textu pomocou knižnice spaCy, ktorá text rozdelila na postupnosť tokenov. Tokenom môže byť slovo alebo iný významový celok a podľa podmienky typu grafu aj interpunkčné znamienka. Aby sme neskôr predišli duplicite tokenov lišiacich sa v použití kapitálok (veľkých písmen), všetky tokeny boli prevedené na malé písmená.

2. Ak tvoríme sieť z lematizovaného textu, nasleduje lematizácia s použitím spaCy, pri ktorej je každý token nahradený svojou lemov. Ak je lema tvorená z viac ako jednej jednotky, oddelíme ich. V prípade, že text nechceme lematizovať, ignorujeme tento krok a pracujeme s pôvodnými tvarmi.
3. Nasleduje tvorba grafu cez knižnicu networkX, v ktorom uzly reprezentujú tokeny - slová a podľa podmienky aj interpunkčné znamienka. Hrana medzi dvoma tokenmi existuje, ak sa nachádzajú v texte vedľa seba. Keďže vzťah susednosti je vzájomný, graf je **neorientovaný**. Slučky sa nevyskytujú, pretože sú v rámci susednosti nezvyčajné. Ak sa susedná dvojica nachádza v texte viackrát, v sieti bude reprezentovaná vždy len jednou hranou, takže nedochádza k viacnásobným hranám. Preto je graf taktiež **neohodnotený** a z toho vychádza, že tvoríme **jednoduché grafy**.

Z vyššie uvedeného vyplýva, že všetky nami vytvorené slovné siete sú **jednoduché neorientované grafy**. Nebudú regulárne, pretože obsahujú uzly s vysokým stupňom (huby) aj uzly s nízkym stupňom. Zároveň sú súvislé – pozostávajú z jedného komponentu, keďže text tvorí súvislý reťazec, v ktorom je každé slovo (s výnimkou prvého a posledného) prepojené so svojím susedom.

2.3.3 Analýza distribúcie stupňov uzlov

Po úspešnom vytvorení všetkých variantov slovných sietí sme pristúpili k štatistickému vyhodnocovaniu distribúcie stupňov uzlov $P(k)$. Samotný výpočet distribúcie bol tiež realizovaný v Pythone. Keďže sme už v predošlých častiach vytvárali graf z knižnice **networkx**, vedeli sme si z neho získať aj zoznam stupňov všetkých uzlov. Pre každý stupeň k sme vypočítali $P(k)$ a výsledky zobrazili v log-log grafe, ktorý sa štandardne využíva na overenie mocninového zákona.



Obr. 2.2: Ukážka nesprávne vizualizovanej distribúcie stupňov uzlov v log-log mierke

Pri priamom zobrazení všetkých vypočítaných hodnôt graf ukazoval výrazný šum a mocninový zákon nebol pekne viditeľný, ako je znázornené na obrázku 2.2. Z tohto dôvodu sme sa rozhodli pre logaritmické binovanie. Tento prístup spočíva v rozdelení dát do intervalov, ktoré sú rovnomerne rozložené na logaritmickú mierku, čím sa zredukuje šum. Hodnota každého intervalu („binu“) bola určená ako priemer jeho dvoch okrajov a pravdepodobnosť výskytu stupňa sa vypočíta takto [31]:

$$P(k) = \frac{n_i}{n \cdot \Delta_i}, \quad (2.1)$$

kde n_i je počet uzlov so stupňom v danom intervale, n je celkový počet uzlov a Δ_i je šírka daného intervalu. Počet intervalov pre každú sieť bol fixne daný na 20, ale v prípade, že sa v niektorom intervale nenachádzal žiadny stupeň, výsledný graf obsahuje menej bodov.

Ak body v grafe podliehajú mocninovému zákonu, odhad škálovacieho exponentu γ vypočítame pomocou knižnice `powerlaw`, ktorá využíva metódu maximálnej vierohodnosti (MLE). Táto metóda okrem γ určuje aj $x_{\min}$, čo predstavuje minimálnu hodnotu stupňa, od ktorej distribúcia nasleduje mocninový zákon.

2.3.4 Aplikovanie Zipfovho zákona

Pre každú jazykovú verziu sme zostrojili zoznam všetkých tokenov spolu s ich početnosťou. Následne sme tokeny zoradili podľa klesajúcej frekvencie a zistili ich poradie R . Pre každé poradie sme určili pravdepodobnosť výskytu $P(R)$ a zobrazili tieto závislosti v grafe.

Na odhadnutie exponentu α sme nevyužili knižnicu `powerlaw`, pretože nie je určená na dáta vo formáte poradie–frekvencia. V tomto prípade sme na výpočet zvolili

metódu lineárnej regresie použitej na celé logaritmované dáta pomocou podmodulu `scipy.stats`.

2.3.5 Aplikovanie Heapsovho zákona

Pre analýzu dynamiky rastu slovnej zásoby v závislosti od celkového rozsahu textu sme aplikovali Heapsov zákon. Pre tento proces sme postupne načítavali text, pri ktorom sme pre každý spracovaný token zaznamenávali aktuálny počet unikátnych uzlov v sieti. Výsledkom sú grafy znázorňujúce funkčnú závislosť počtu unikátnych slov $V(L)$ od danej dĺžky textu L . Na odhadnutie exponentu β sme zvolili metódu lineárnej regresie aplikovanej na log-log transformované dáta pomocou knižnice `scipy.stats`.

Kapitola 3

Porovnanie sietí a výsledky

V tejto kapitole prezentujeme výsledky analýzy slovných sietí vytvorených zo šiestich jazykových verzií Kafkovej Premeny. Cieľom je porovnať štruktúru sietí v dvoch variantoch, bez interpunkcie a s interpunkciou, a zistiť, ako prítomnosť interpunkčných znamienok ovplyvňuje základné topologické vlastnosti. Pre prehľadnosť sú v texte percentuálne zmeny zaokrúhlené na celé čísla.

Najprv sa zameriavame na základné charakteristiky sietí (počet uzlov, hrán a hustotu) a na doplnkové topologické metriky (priemerný stupeň, koeficient zhukovania a priemernú dĺžku najkratšej cesty). Následne analyzujeme frekvenciu slov a slovnú zásobu a identifikujeme najfrekvencovanejšie tokeny a overujeme platnosť Zipfovho a Heapsovho zákona. Ďalej sa venujeme distribúcii stupňov uzlov, ktorá nám umožňuje posúdiť, či skúmané siete vykazujú vlastnosti bezškálových sietí, a sledujeme, ako sa škálovací exponent γ mení po zahrnutí interpunkcie.

V závere kapitoly sa venujeme vplyvu lematizácie na štruktúru sietí. Znova analyzujeme zmeny základných charakteristík, topologických metrík a distribúcie stupňov po zjednotení slovných tvarov. Vzhľadom na to, že lematizácia umelo zvyšuje frekvencie slov Zipfov a Heapsov zákon pre lematizované texty neuvádzame.

Jednotlivé jazyky sú v rámci kapitoly porovnávané navzájom, čo umožňuje identifikovať spoločné vzorce aj jazykovo špecifické odchýlky.

3.1 Základné charakteristiky sietí

Keď už máme úspešne vytvorené slovné siete, prvým krokom analýzy bolo porovnanie základných štatistík vytvorených sietí, konkrétnejšie počtu uzlov n , počtu hrán e a hustoty ρ . Tieto charakteristiky poskytujú základný prehľad o veľkosti a štruktúre každej siete.

V tabuľke 3.1 sú uvedené hodnoty pre siete z textov bez interpunkcií. Z týchto nameraných hodnôt možno pozorovať niekoľko kľúčových vlastností. Najnižší počet

Jazyk	Uzly (n)	Hrany (e)	Hustota (ρ)
nemčina	3731	13447	0,001933
angličtina	2552	12450	0,003825
holandčina	3355	13518	0,002403
španielčina	3495	12709	0,002081
taliančina	3967	13136	0,001670
portugalčina	3653	13437	0,002014

Tabuľka 3.1: Základné charakteristiky sietí (počet uzlov n , počet hrán e a hustota ρ) z textov jednotlivých jazykov bez interpunkcie

uzlov má sieť anglickej verzie, čo môže súvisieť s analytickým charakterom anglického jazyka [5]. Angličtina využíva minimálne ohýbanie slov (časovanie alebo skloňovanie), čo v grafovom modeli vedie k vzniku menšieho počtu unikátnych uzlov. Ak sa pozrieme späť na tabuľku 2.1, môžeme si všimnúť, že anglická sieť obsahuje najvyšší počet slov spomedzi vybraných jazykov. V kombinácii s nižším počtom uzlov to naznačuje, že sa tie isté slová v texte často opakujú. Naopak, najvyšší počet uzlov má talianska sieť. Tento jav môže byť dôsledkom ohybného charakteru a bohatej morfológie taliančiny [5]. Na rozdiel od angličtiny, využíva široké množstvo koncoviek pri časovaní a skloňovaní mien, čo v sieti vytvára množstvo samostatných uzlov.

V počte hrán nie sú rozdiely medzi jazykmi také výrazné ako pri počte uzlov. Hoci taliančina má približne o 55% viac uzlov ako angličtina, počet jej hrán je vyšší len o niečo vyše 5%. To naznačuje, že morfológická bohatosť jazyka, ktorá sa prejavuje vyšším počtom unikátnych slovných tvarov, nemusí automaticky viesť k úmernému nárastu počtu hrán. Sieť síce obsahuje viac unikátnych slov, ale ich susedstvá sú porovnateľne husté ako v jazykoch s jednoduchšou morfológiou.

Z hľadiska hustoty siete má najvyššiu hodnotu tiež angličtina a najnižšiu taliančina. Tento rozdiel súvisí s počtom uzlov a hrán. Angličtina s malým počtom uzlov a veľkým počtom hrán vytvára hustejšiu sieť, zatiaľ čo taliančina s veľkým počtom uzlov a menším počtom hrán je výrazne redšia.

Ostatné jazyky sa svojimi hodnotami počtu uzlov a hustoty pohybujú medzi extrémami angličtiny a taliančiny.

Po zahrnutí interpunkcie do analýzy možno sledovať v tabuľke 3.2 nárast hodnôt u všetkých veličín. Počet uzlov sa zvýšil od 8 - 11 uzlov v každej sieti, čo zodpovedá pridaniu interpunkčných znamienok ako nových unikátnych prvkov siete. Je dôležité poznamenať, že hoci analyzované texty vychádzajú z rovnakého sémantického základu, jednotlivé jazyky nepoužívajú identické interpunkčné systémy. Rozdiely sa prejavujú nielen v type používaných znamienok, ale aj v pravidlách ich používania.

K nárastu počtu hrán po pridaní interpunkcie došlo vo všetkých jazykoch, napríklad

Jazyk	Uzly (n)	Hrany (e)	Hustota (ρ)
nemčina	3739	13546	0,001938
angličtina	2563	12582	0,003832
holandčina	3366	13807	0,002438
španielčina	3506	12771	0,002079
taliančina	3978	13545	0,001712
portugalčina	3662	13691	0,002042

Tabuľka 3.2: Základné charakteristiky sietí (počet uzlov n , počet hrán e a hustota ρ) z textov jednotlivých jazykov s interpunkciou

taliančina zaznamenala nárast o 409 hrán, kým nemčina len o 99. Tento nárast, ktorý je nižší než by sme očakávali, nie je spôsobený len tvorbou nových hrán, ale aj zánikom pôvodných susedností medzi slovami, ktoré boli nahradené hranami s interpunkciou. Práve preto môžu mať interpunkčné znamienka v sieti vysoký stupeň, hoci celkový počet hrán vzrástol len mierne.

Hustota siete sa po pridání interpunkcie mierne zvýšila vo všetkých jazykoch, pričom angličtina si naďalej udržiava najvyššiu hustotu a taliančina najnižšiu. Poradie jazykov podľa hustoty, ale aj podľa počtu hrán zostalo takmer rovnaké ako v sieťach bez interpunkcie. Topologická štruktúra slovnej siete je tak primárne definovaná lexikálnou a syntaktickou povahou daného jazyka, nie prítomnosťou interpunkcie.

3.1.1 Doplnkové metriky

Okrem počtu uzlov, hrán a hustoty sme pre každú sieť vypočítali aj priemerný stupeň $\langle k \rangle$, priemerný koeficient zhlukovania C a priemernú dĺžku najkratšej cesty $\langle d \rangle$. Hodnoty týchto metrík v sieťach bez a vrátane interpunkcie sú uvedené v tabuľke 3.3.

	$\langle k \rangle$		C		$\langle d \rangle$	
Jazyk	bez	s	bez	s	bez	s
nemčina	7,208	7,246	0,258	0,356	3,104	2,932
angličtina	9,757	9,818	0,396	0,454	2,792	2,730
holandčina	8,058	8,204	0,338	0,412	2,950	2,844
španielčina	7,273	7,285	0,313	0,418	2,917	2,802
taliančina	6,623	6,810	0,199	0,292	3,149	2,998
portugalčina	7,357	7,477	0,293	0,407	2,971	2,826

Tabuľka 3.3: Priemerný stupeň $\langle k \rangle$, koeficient zhlukovania C a priemerná najkratšia vzdialenosť $\langle d \rangle$ pre jazyky s označením bez/s pre siete bez interpunkcie a s ňou

Priemerný stupeň $\langle k \rangle$ vo všetkých sieťach nadobúda relatívne nízke hodnoty, pri-

bližne od 6,6 po 9,8. Najvyššie hodnoty dosahuje angličtina, čo potvrdzuje predpoklad, že v analytických jazykoch s menším počtom unikátnych slovných tvarov sú jednotlivé slová prepojené s väčším počtom susedov. Naopak, taliančina má najnižší priemerný stupeň, čo súvisí s jej bohatšou morfológiou, väčším počtom uzlov a menej hustou štruktúrou siete. Po pridaní interpunkčných znamienok sa priemerný stupeň mierne zvýšil vo všetkých jazykoch. Interpunkčné znamienka totiž vytvárajú nové spojenia medzi slovami a v sieti niektoré fungujú ako vysoko prepojené uzly. Priemerný stupeň uzla $\langle k \rangle$ celkovo súvisí s hustotou siete.

Koeficient zhlukovania C nadobúda pomerne vysoké hodnoty, čo je typické pre reálne siete. Najvyššie hodnoty dosahuje angličtina, zatiaľ čo najnižšie taliančina, čo korešponduje s rozdielmi v hustote a priemernom stupni sietí. Po zahrnutí interpunkcie došlo vo všetkých jazykoch k výraznému nárastu koeficientu zhlukovania. Tento nárast naznačuje, že interpunkčné znamienka nepripájajú slová náhodne, ale podporujú vznik lokálnych susedstiev. Po zahrnutí interpunkcie sa síce poradie niektorých jazykov mierne zmenilo, avšak angličtina si naďalej zachovala najvyššie hodnoty koeficientu zhlukovania a taliančina najnižšie.

Priemerná dĺžka najkratšej cesty $\langle d \rangle$ sa vo všetkých sieťach pohybuje približne medzi hodnotami 2,7 až 3,1, čo je vzhľadom na tisíce uzlov v sieti pomerne nízka hodnota. Najnižšie hodnoty dosahuje angličtina, zatiaľ čo najvyššie taliančina, čo opäť súhlasí s rozdielmi v hustote a v počte uzlov jednotlivých sietí. Hustejšia anglická sieť obsahuje viac prepojení, a preto vyžaduje pri prechode medzi slovami menší počet krokov. Po pridaní interpunkcie sa vo všetkých jazykoch hodnota mierne znížila. Najmenší pokles zaznamenala angličtina, čo môže súvisieť s tým, že jej sieť bola už pred zahrnutím interpunkcie pomerne hustá a kompaktná. Naopak, najvýraznejší pokles nastal v nemčine, kde interpunkčné znamienka vytvorili viac nových prepojení medzi vzdialenejšími časťami siete. Interpunkčné znamienka teda fungujú ako „skratky“ v sieti, keďže susedia s veľkým množstvom rôznych slov a umožňujú efektívnejšie prepojenie vzdialenejších častí siete.

Jednotlivé metriky pritom medzi sebou úzko súvisia. Vyššia hustota siete sa prejavuje aj vyšším priemerným stupňom uzlov, väčším koeficientom zhlukovania a kratšími priemernými vzdialenosťami medzi uzlami. Naopak, menej husté siete s väčším počtom uzlov dosahujú nižšiu mieru lokálnej prepojenosti a dlhšie najkratšie cesty. Nízke hodnoty priemernej najkratšej vzdialenosti spolu s pomerne vysokým koeficientom zhlukovania zároveň predstavujú charakteristické vlastnosti sietí typu „small-world“.

3.2 Frekvencia slov a slovná zásoba

Dôležitým aspektom analýzy textov je skúmanie slovnej zásoby a frekvencie výskytu jednotlivých slov. Frekvencia slov priamo ovplyvňuje štruktúru slovnej siete a uzly slov, ktoré sa v texte vyskytujú často, majú tendenciu susediť s väčším počtom uzlov rôznych slov a nadobúdať vyšší stupeň. V tejto časti sa zameriame na najpočetnejšie tokeny v každom jazyku a porovnáme, ako sa poradie najfrekventovanejších slov mení v závislosti od zahrnutia interpunkcie do analýzy.

3.2.1 Najfrekventovanejšie prvky

V tabuľke 3.4 je uvedených desať najfrekventovanejších tokenov pre každý jazyk v sieti bez interpunkcie. Vo všetkých analyzovaných jazykoch dominujú krátke gramatické slová – členy, predložky, spojky a zámená. Tieto slová sa v texte vyskytujú opakovane, čo je pravdepodobne dôsledkom gramatickej štruktúry každého jazyka. Naopak, plnovýznamové slová (napr. slovesá s konkrétnym dejom, podstatné či prídavné mená) sa medzi najfrekventovanejšími takmer nevyskytujú. Výnimkou je meno *Gregor*, ktoré sa objavuje v niektorých jazykoch medzi najčastejšími tokenmi, ale to priamo súvisí s charakterom analyzovaného textu, ktorého dej sa sústreďuje na hlavnú postavu s týmto menom.

	nemčina	angličtina	holandčina	španielčina	taliančina	portugalčina
1	die (626)	the (1155)	de (949)	la (1021)	la (587)	a (794)
2	und (624)	to (753)	en (643)	de (939)	e (528)	de (627)
3	der (452)	and (642)	zijn (514)	que (701)	di (492)	o (624)
4	er (444)	he (590)	hij (508)	y (644)	il (362)	e (593)
5	zu (428)	his (550)	het (464)	el (524)	si (356)	que (555)
6	dem (382)	of (436)	te (400)	a (509)	che (353)	se (393)
7	in (362)	was (414)	een (367)	en (504)	non (322)	não (321)
8	sich (311)	it (370)	van (360)	se (455)	a (263)	para (265)
9	sie (304)	had (359)	in (343)	con (305)	gregor (239)	com (263)
10	nicht (260)	in (348)	dat (296)	no (301)	in (239)	gregor (246)

Tabuľka 3.4: Najfrekventovanejšie tokeny pre jazykové verzie bez zahrnutia interpunkcií

Všimnúť si môžeme aj fakt, že na prvom mieste v každom jazyku sa nachádza určitý člen, čo potvrdzuje jeho kľúčovú úlohu v syntaktickej štruktúre viet. V angličtine je to člen *the* (rodovo neutrálny), v nemčine *die* (ženský rod, ale používa sa aj ako množné číslo), v španielčine a taliančine *la* (ženský rod), v holandčine *de* (spoločný pre mužský a ženský rod) a v portugalčine *a* (ženský rod). Zaujímavá je miera dominancie prvého miesta – napríklad v angličtine má člen *the* približne o 53% vyššiu frekvenciu ako druhé slovo v poradí, v holandčine je náskok člena *de* zhruba o 47%. To môže naznačovať, že

tieto dva jazyky sa vo väčšej miere spoliehajú na členy ako ostatné sledované jazyky, kde rozdiely medzi prvou a druhou priečkou nie sú také extrémne.

Častá je aj spojka „a“, ktorá sa v jazykoch nachádza medzi prvými dvomi až štyrmi najfrekventovanejšími slovami (anglické *and*, nemecké *und*, holandské *en*, španielske *y*, talianske a portugalské *e*). Všimnúť si môžeme aj prítomnosť záporu v týchto 10 priečkových slovách v románskych jazykoch (španielske *no*, talianske *non*, portugalské *não*) a v nemčine (*nicht*).

	Nemčina	Angličtina	Holandčina	Španielčina	Taliančina	Portugalčina
1	, (1868)	, (1293)	, (1268)	, (1860)	, (1081)	, (1552)
2	. (626)	the (1155)	de (949)	la (1021)	. (628)	a (794)
3	die (626)	to (753)	en (643)	de (939)	la (587)	. (647)
4	und (624)	. (734)	. (626)	que (701)	e (528)	de (627)
5	der (452)	and (642)	zijn (514)	y (644)	di (492)	o (624)
6	er (444)	he (590)	hij (508)	. (628)	il (362)	e (593)
7	zu (428)	his (550)	het (464)	el (524)	si (356)	que (555)
8	dem (382)	of (436)	te (400)	a (509)	che (353)	se (393)
9	in (362)	was (414)	een (367)	en (504)	non (322)	não (321)
10	sich (311)	it (370)	van (360)	se (455)	a (263)	para (265)

Tabuľka 3.5: Najfrekventovanejšie tokeny pre jazykové verzie so zahrnutím interpunkcie

Zahrnutie interpunkcie ako samostatných tokenov vedie k výraznej zmene v poradí najfrekventovanejších prvkov. Zo všetkých interpunkčných znamienok sa do prvých 10 najfrekventovanejších prvkov podľa tabuľky 3.5 dostali iba bodka a interpunkcia. Čiarka sa vyšplhala na prvú priečku v každom jazyku, čo je rovnaký výsledok ako v pozorovaniach Kuliga (pozri 1.4.1). Bodka sa v rebríčku taktiež posunula výrazne nahor, hoci neobsadzuje fixnú pozíciu. Podrobenjší pohľad na interpunkčné znamienka v tabuľke 3.6 ukazuje aj poradie iných znamienok. Naše výsledky sa však v niektorých bodoch líšia od pozorovaní Kuliga. Kým Kulig uvádza, že bodka sa vo väčšine jazykov nachádza na 2. až 3. mieste, v našom prípade sa pohybuje sa v rozmedzí 2. až 6. miesta. Otáznik a výkričník tiež nezodpovedajú jeho tvrdeniam, keďže v našej analýze sa otáznik nachádza približne medzi 43. až 72. miestom a výkričník medzi 55. až 82. miestom. Na rozdiel od Kuliga [19] sme v analýze ponechali aj úvodzovky a zátvorky. Zátvorky ovplyvňujú najmä nižšie priečky rebríčka, no úvodzovky siahajú vyššie, medzi 11. až 17. miesto. Bodkočiarka je s jeho výsledkami v zásade konzistentná, ale dvojbodka nie, pretože sa nachádza na nižších priečkach než uvádza Kulig.

Rozdiely v poradí interpunkčných znamienok a ich frekvenciou preto pravdepodobne súvisia najmä s výberom analyzovaného textu a jeho charakterom. Frekvencia jednotlivých znamienok môže byť ovplyvnená napríklad štýlom autora, množstvom dialógov či celkovou štruktúrou viet. Z toho vyplýva, že poradie interpunkčných znamienok nie je pevne dané a nesleduje univerzálne vzorce.

	nemčina	angličtina	holandčina	španielčina	taliančina	portugalčina
,	1. (1868)	1. (1293)	1. (1268)	1. (1860)	1. (1081)	1. (1552)
.	2. (626)	4. (734)	4. (626)	6. (628)	2. (628)	3. (647)
"	12. (262)	16. (262)	17. (252)	15. (264)	11. (262)	12. (262)
;	22. (168)	25. (170)	24. (172)	30. (122)	19. (179)	16. (196)
-	35. (92)	55. (77)	40. (88)	47. (66)	32. (90)	19. (179)
?	52. (58)	72. (55)	59. (57)	49. (63)	43. (62)	46. (67)
!	72. (43)	82. (43)	71. (42)	55. (51)	57. (45)	64. (45)
:	114. (26)	152. (22)	125. (24)	73. (35)	76. (36)	70. (40)
(	—	671. (4)	2034. (1)	2307. (1)	1415. (2)	—
)	—	672. (4)	2036. (1)	2308. (1)	1416. (2)	—
...	—	2406. (1)	3164. (1)	2308. (1)	3674. (1)	960. (3)

Tabuľka 3.6: Poradie interpunkčných znamienok podľa frekvencie výskytu v jednotlivých jazykoch. V zátvorkách je uvedená absolútna frekvencia.


3.2.2 Zipfov a Heapsov zákon

V tejto časti overujeme platnosť Zipfovho a Heapsovho zákona pre jednotlivé jazykové verzie textu. Najprv sme aplikovali Zipfov zákon pre texty bez interpunkcií. Z vizualizácie na obrázku 3.1 je zrejmé, že frekvencia výskytu slov vo všetkých skúmaných jazykoch sleduje mocninový charakter. Rovnako ako aj pri výskume Kuliga, tokeny s najväčšou frekvenciou sa odchyľujú od mocninového zákona. Tieto tokeny predstavujúce najmä krátke gramatické slová (členy, predložky, spojky, zámená) skresľujú výpočet exponentu α a preto pri jeho odhadovaní bolo vynechaných prvých desať najfrekventovanejších tokenov z poradia, čo je rovnaký postup ako použil Kulig [19].


Hodnoty exponentu α z výsledkov na obrázku 3.1 sa pohybujú medzi hodnotami 0,912 až 1,18. Tieto výsledky sú v súlade s teroetickými predpokladmi, podľa ktorých sa exponent pre prirodzené jazyky nachádza zvyčajne v rozmedzí od 0,7 do 1,2 (podľa časti 1.2.1).

Práve angličtina má najvyšší exponent ($\alpha = 1,18$), čo sa prejavuje najstrmším sklonom. Tento fakt suvisí s nižším počtom uzlov a nižšou komplexnosťou lexiky v porovnaní s ostatnými jazykmi. Taliančina má naopak najnižší exponent ($\alpha = 0,912$) a jej menšia smernica priamky znamená, že má bohatšiu slovnú zásobu jazyka, čo súhlasí s najvyšším počtom uzlov spomedzi všetkých pozorovaných jazykov [20].

Tieto výsledky úzko súvisia s Heapsovým zákonom a jeho vizualizáciu pre všetky jazyky môžeme vidieť na obrázku 3.2. Je viditeľné, že rast slovnej zásoby s dĺžkou textu má sublineárny charakter, čo je v súlade s očakávaniami. Namerané hodnoty exponentu β sa pohybujú v rozmedzí približne 0,47 až 0,66, pričom najvyššiu hodnotu dosahuje taliančina a najnižšiu angličtina, čo súhlasí s predpokladmi opisovanými v predošlých častiach. Toto správanie zodpovedá vzťahu 1.15, podľa ktorého nižšie hodnoty Zipfovho exponentu α vedú k rýchlejšiemu rastu slovnej zásoby (vyššej hodnote β) a naopak.



Obr. 3.1: Zobrazenie Zipfovho zákona pre jazykové verzie bez interpunkcie – závislosť pravdepodobnosti výskytu slova $P(R)$ od jeho poradia R v logaritmickej mierke. Čierne body predstavujú empirické frekvencie slov, červená prerušovaná priamka znázorňuje správanie podľa Zipfovho zákona s exponentom α .



Obr. 3.2: Zobrazenie Heapsovho zákona pre jazykové verzie bez interpunkcie – závislosť počtu rôznych slov $V(L)$ od celkového počtu slov L v logaritmickej miere. Čierne body predstavujú empirické dáta, ktoré ilustrujú rast slovnej zásoby so zvyšujúcou sa veľkosťou textu a červená prerusovaná priamka znázorňuje správanie podľa Heapsovho zákona s exponentom β .

Presne numerické hodnoty však už tomuto vzťahu úplne nezodpovedajú. Z hodnôt uvedených v tabuľke 3.7 vyplýva, že niektoré očakávané hodnoty exponentu β dokonca prekračujú interval $0 < \beta < 1$, ktorý by mal Heapsov exponent spĺňať (pozri časť 1.2.1). Ako bolo uvedené v teórii o tomto zákone, výpočet β platí pre nekonečne dlhé texty a v našom prípade ide o texty s dĺžkou približne 17 000 až 22 000 slov (tab. 2.1). Je to menej, než by bolo potrebné na presné splnenie vzťahu a to spôsobuje skreslenie našich výsledkov. Okrem toho, pri odhade Zipfovho exponentu sme podľa metodiky Kuliga vynechali prvých desať najfrekvencovanejších tokenov, čo síce zlepšuje α , ale zároveň ovplyvňuje aj presnosť Heapsovho exponentu, ktorý by mal v ideálnom prípade zahŕňať všetky slová vrátane tých najfrekvencovanejších.

nemčina	angličtina	holandčina	španielčina	taliančina	portugalčina
1,050	0,847	0,973	1,022	1,096	1,030

Tabuľka 3.7: Očakávané hodnoty Heapsovho exponentu pre jednotlivé jazyky vyrátané podľa exponentu α


Po pridaní interpunkcie do analýzy sa hodnoty exponentov α v obrázku 3.3 mierne zvýšili v každom jazyku, a to v rozmedzí od 0,019 do 0,021. Najväčší nárast zaznamenala španielčina, angličtina a portugalčina, naopak najmenší taliančina. Tento jav je v súlade s pozorovaniami Kuliga [19], ktorý uvádza, že zahrnutie interpunkcie do analýzy vedie k lepšiemu škálovaniu Zipfovho rozdelenia. Túto zmenu si môžeme všimnúť najmä v oblasti najvyšších hodnôt poradia, kde v porovnaní s obrázkom 3.1 prvé body na grafoch ležia bližšie k priamke mocninového zákona. V konečnom dôsledku sa interpunkčné znamienka nesprávajú ako cudzí prvok, ale ako kľúčová štruktúrna zložka.

3.3 Distribúcia stupňov uzlov


Zipfov zákon a distribúcia stupňov tvoria komplexný obraz o jazyku ako systéme, no zatiaľ čo sa Zipfov zákon pozerá na frekvenciu slov, distribúcia stupňov ponúka pohľad na štruktúru siete. Analýza distribúcie stupňov uzlov nám umožňuje posúdiť, či skúmané slovné siete prejavujú vlastnosti bezškálových sietí. Pre každý jazyk bol zistený škálovací exponent γ .

Z obrázku 3.4 možno vidieť, že distribúcia stupňov uzlov vo všetkých šiestich jazykoch nasleduje mocninový zákon, a to od hodnoty x_{min} . Hodnoty exponentu γ sa pohybujú v rozmedzí 2,046 až 2,203 a sú v súlade s teóriou, podľa ktorej sa exponent nachádza v intervale $2 < \gamma < 3$ (pozri časť 1.16). Tieto výsledky potvrdzujú bezškálový charakter slovných sietí.

Všetky namerané γ hodnoty sú približne menšie ako 2,2 a bližšie k dolnej hranici (2)



Obr. 3.3: Zobrazenie Zipfovho zákona pre jazykové verzie s interpunkciou – závislosť pravdepodobnosti výskytu slova $P(R)$ od jeho poradia R v logaritmickej mierke. Čierne body predstavujú empirické frekvencie slov, červená prerušovaná priamka znázorňuje správanie podľa Zipfovho zákona s exponentom α .



Obr. 3.4: Distribúcia stupňov uzlov pre jazykové verzie bez interpunkcie - závislosť pravdepodobnosti $P(k)$ od stupňa uzla k v log-log mierke. Čierne body predstavujú empirické dáta, červená prerušovaná priamka znázorňuje správanie podľa mocninového zákona s exponentom γ .

ako k hornej (3). Tento fakt nie je náhodný, ale odráža vlastnosť prirodzeného jazyka - jeho dynamickosť. Ľudský jazyk neustále podlieha procesu pretvárania významov. Slová získavajú nové kontexty a zároveň strácajú tie staré. V terminológii teórie sietí sa tento jav nazýva prepájanie („rewiring”) [24]. Práve tento proces spôsobuje, že γ klesá smerom k hodnote 2. Naopak, ak by jazyk iba rástol a staré spojenia by nikdy nezanikali, exponent by stúpil k hodnote 3. Jazyk nie je len rastúcou sieťou, ale aj prepájanou sieťou.

Podľa Barabásiho [2] tieto nižšie hodnoty exponentu γ zodpovedajú pomalšiemu poklesu distribúcie stupňov, čo vedie k „fat-tailed” distribúcii a vyššiemu výskytu hubov. Huby v jazykových sieťach nie sú náhodné slová, pretože predstavujú najčastejšie používané slová, ktoré tvoria komunikačný základ. Tento základ môžeme charakterizovať ako jadro lexikónu [23, 24].

Konkrétnejšie rozdiely v hodnotách škálovacieho exponentu sú viditeľné medzi holandčinou a angličtinou. Najnižšiu hodnotu $\gamma = 2,046$ dosahuje angličtina, čo znamená, že má najvýraznejšie huby spomedzi všetkých analyzovaných jazykov. Tento fakt súvisí s analytickým charakterom angličtiny a je v súlade s jej nízkym počtom uzlov. Naopak, najvyššiu hodnotu $\gamma = 2,203$ má holandčina, čo naznačuje rovnomernejšie rozloženie spojení medzi uzlami a menej dominantné huby.


Rozdiely sú značné aj v hodnotách $x_{\min}$, ktoré sa pohybujú v rozmedzí od 6 (angličtina) do 17 (holandčina). Táto hodnota určuje hranicu, od ktorej distribúcia nasleduje mocninový zákon. Jazyky s vyšším $x_{\min}$ majú väčšiu oblasť nízkych stupňov, ktorá sa od mocninového zákona odchyľuje.

Pri porovnávaní jazykových rodín si možno všimnúť zaujímavý vzor. Románske jazyky majú prekvapivo podobné hodnoty γ (2,115 - 2,152). Germánske jazyky majú naopak väčší rozptyl, od 2,046 (angličtina) po 2,203 (holandčina), čo pravdepodobne odráža štrukturálne rozdiely medzi analytickou angličtinou a morfológicky bohatšou nemčinou a holandčinou.

Po pridaní interpunkcie došlo k zmene škálovacieho exponentu γ vo všetkých jazykoch, avšak smer tejto zmeny nie je jednotný, ako môžeme vidieť na obrázku 3.5. V angličtine, nemčine a španielčine hodnota exponentu vzrástla, zatiaľ čo v holandčine, taliančine a portugálčine klesla. Rozdiely sú však malé, maximálna absolútna zmena je 0,091 a hodnoty γ sa pohybujú v rozmedzí 2,106 – 2,183.

V jazykoch s nárastom γ viedlo pridanie interpunkcie k oslabeniu chvosta, čo znamená, že podiel hubov sa v pomere k ostatným uzlom mierne znížil. V týchto sieťach interpunkčné znamienka síce pribudli, ale nestali sa o toľko výraznejšími hubmi než pôvodné huby. V jazykoch s poklesom γ viedlo pridanie interpunkcie naopak k posilneniu bezškálového charakteru, kde nové interpunkčné uzly, pravdepodobne čiarka a bodka, začali dominovať ako silné huby, čím spôsobili strmší sklon distribúcie.

Z hľadiska vývoja γ aj α zároveň, neexistuje jednoduchý vzťah medzi ich zmenami.



Obr. 3.5: Distribúcia stupňov uzlov pre jazykové verzie so zahrnutím interpunkcie - závislosť pravdepodobnosti $P(k)$ od stupňa uzla k v log-log mierke. Čierne body predstavujú empirické dáta, červená prerušovaná priamka znázorňuje správanie podľa mocninového zákona s exponentom γ .

Angličtina zaznamenala najväčší nárast α po pridaní interpunkcie o 0,021 spolu s nárastom γ o 0,091. Taliančina s najmenším nárastom α o 0,019 zaznamenala pokles γ o 0,015. Tieto rozdiely potvrdzujú, že vzťah medzi frekvenciou slov a štruktúrou susedností nie je priamočiary. Zmena γ je komplexnejšia a nemusí priamo korešpondovať so zmenou α , pretože pri výpočte Zipfovho zákona do frekvenčného zoznamu tokeny iba pribúdajú, zatiaľ čo pri tvorbe slovnej siete s pridaním interpunkcie sa hrany mažú, aj pridávajú.

Podľa vzťahu 1.18 sú v tabuľkách 3.8 a 3.9 uvedené očakávané hodnoty γ pre siete bez interpunkcie a s ňou. Všimame si, že sa ani jedna reálne nameraná γ neblíži k tej očakávanej hodnote, pretože všetky reálne γ sú vyššie. Najväčší rozdiel možno pozorovať pri angličtine, kde sa očakávaná hodnota (1,847) od reálnej (2,046) odchyľuje najviac. Tento rozdiel potvrdzuje, že vzťah 1.18 neplatí presne pre texty s našou dĺžkou slov (17000 - 22000).

nemčina	angličtina	holandčina	španielčina	taliančina	portugalčina
2,050	1,847	1,973	2,022	2,096	2,030

Tabuľka 3.8: Očakávané hodnoty škálovacieho exponentu γ pre siete jednotlivých jazykov bez interpunkcie vyrátané podľa exponentu α

nemčina	angličtina	holandčina	španielčina	taliančina	portugalčina
2,029	1,833	1,954	2,001	2,074	2,008

Tabuľka 3.9: Očakávané hodnoty škálovacieho exponentu γ pre siete jednotlivých jazykov s interpunkciou vyrátané podľa exponentu α

Napriek všetkým odchýlkam a pozorovaniam hodnoty γ stále spĺňajú podmienku $2 < \gamma < 3$, čo potvrdzuje, že slovné siete v oboch verziách majú bezškálové vlastnosti. Pridanie interpunkcie nemení topologický charakter sietí, iba jemne moduluje hodnotu škálovacieho exponentu v závislosti od jazyka.

3.4 Vplyv lematizácie textov na sieť

Doterajšia analýza vychádzala z pôvodných textov, v ktorých bol každý slovný tvar reprezentovaný ako samostatný uzol siete. V prirodzených jazykoch však môže jedno slovo vystupovať v mnohých gramatických podobách, napríklad v rôznych pádoch, časoch alebo rodoch. Z tohto dôvodu bola ďalším krokom analýzy lematizácia textov, pri ktorej boli jednotlivé slovné tvary prevedené na ich základný tvar – lemu.

Lematizácia odstráni morfológickú rozmanitosť a zjednotí slová. V sieťovom modeli to znamená, že viaceré uzly reprezentujúce rôzne tvary toho istého slova sa zlúčia do jedného uzla, čo môže ovplyvniť topológiu siete. Očakávame, že tento proces výrazne zníži počet unikátnych uzlov v sieti, čo povedie k zvýšeniu hustoty a priemerného

stupňa a k zníženiu priemernej nakratšej cesty. Zjednotenie slovných tvarov by malo ovplyvniť aj frekvenčné rozdelenie tokenov a distribúciu stupňov uzlov, keďže frekvencie a spojenia pôvodne rozdelené medzi viaceré slovné tvary sa sústredia do jednej lemy. Najvýraznejšie zmeny pritom očakávame pri morfológicky bohatších jazykoch, zatiaľ čo pri analytickej angličtine by mal byť efekt lematizácie slabší.

3.4.1 Základné charakteristiky lematizovaných sietí

Podľa výsledkov v tabuľke 3.10, lematizácia výrazne znížila počet uzlov n vo všetkých sieťach v porovnaní so sieťami z pôvodných textov (tabuľky 3.1 a 3.2). Počet uzlov klesol v holandčine o približne 17 %, v angličtine o 20 %, v nemčine o 22 %, v taliančine a portugálčine o 31 % a v španielčine o 36 %. Z hľadiska jazykových rodín možno pozorovať, že románske jazyky vykazujú výraznejší pokles, pohybujúci sa okolo 31 – 36%, zatiaľ čo germánske jazyky dosahujú pokles len okolo 17 – 22%. V rámci tejto analýzy sa ukazuje, že románske jazyky vykazujú v pôvodných textoch väčšiu morfológickú rôznorodosť než germánske jazyky. Či tento jav platí aj globálne mimo našu štúdiu by bolo potrebné vykonať analýzu na rozsiahlejšej vzorke.

	n		e		ρ	
Jazyk	bez	s	bez	s	bez	s
angličtina	2029	2040	11405	11513	0,005543	0,005536
nemčina	2902	2910	11872	11947	0,002820	0,002823
holandčina	2785	2796	12798	13023	0,003301	0,003333
španielčina	2235	2246	10579	10577	0,004238	0,004195
taliančina	2744	2755	11070	11433	0,002937	0,003014
portugálčina	2525	2534	11250	11383	0,003530	0,003547

Tabuľka 3.10: Základné charakteristiky sietí z lematizovaných textov (počet uzlov n , počet hrán e a hustota ρ) pre jednotlivé jazyky. Stĺpce „bez“ a „s“ označujú siete bez interpunkcie a s interpunkciou.

Rovnako ako počet uzlov, aj počet hrán e po lematizácii klesol, no nie v rovnakej miere. Najviac v španielčine približne zhruba o 17%, v portugálčine a taliančine okolo 16%, v nemčine približne o 12%, v angličtine o 8% a v holandčine o 5 %. Poradie jazykov podľa veľkosti poklesu je rovnaké pre počet uzlov aj počet hrán.

Hustota ρ sa po lematizácii naopak výrazne zvýšila – najviac v španielčine (približne o 104%), v taliančine (o 76%), v portugálčine (o 75%), v nemčine (o 46%), v angličtine (o 45%) a v holandčine (o 37%). Hustota siete sa zvýšila, pretože počet uzlov po lematizácii klesol viac než počet hrán. Stále si môžeme všimnúť, že poradie jazykov podľa veľkosti nárastu hustoty je rovnaké ako pri poklese počtu uzlov – najväčšie zmeny

opäť dosahujú románske jazyky, zatiaľ čo germánske jazyky zaznamenali výrazne menší nárast.

Z hľadiska stability štruktúry sa ako najstálejšia javí holandčina. Vykazuje najmenšie percentuálne zmeny vo všetkých sledovaných parametroch, čo z nej v rámci našej vzorky robí jazyk s najnižšou mierou morfolologickej pestrosti.

Pridanie interpunkcie v lematizovaných textoch má podobne ako v pôvodných textoch len minimálny vplyv. Počet uzlov sa zvýšil o 8–11 uzlov v každom jazyku, hustota sa zmenila len nepatrne, bez jednoznačného smeru – v niektorých jazykoch mierne klesla, v iných stúpila. Zaujímavým pozorovaním je zmena hrán. Zatiaľ čo v ostatných jazykoch pribudlo 75 až 363 hrán, v španielčine sme zaznamenali pokles o 2 hrany. Tento nezvyčajný jav znamená, že v španielčine interpunkcia zrušila viac spojení medzi slovami, než nových vytvorila.

Napriek výrazným zmenám spôsobeným lematizáciou zostáva angličtina naďalej jazykom s najnižším počtom uzlov, zatiaľ čo najviac uzlov má po lematizácii nemčina. Pôvodne mala najviac uzlov taliančina, ktorá však zaznamenala výrazný pokles.

3.4.2 Topologické metriky lematizovaných sietí

V tabuľke 3.11 sú uvedené topologické metriky pre lematizované siete. Porovnaním s pôvodnými sieťami (tabuľka 3.3) možno sledovať výrazné zmeny vo všetkých sledovaných parametroch, ktoré potvrdzujú prechod od morfologicky bohatej štruktúry k zjednodušenejšej sieti.

Jazyk	$\langle k \rangle$		C		$\langle d \rangle$	
	bez	s	bez	s	bez	s
angličtina	11,242	11,287	0,449	0,500	2,706	2,651
nemčina	8,182	8,211	0,378	0,454	2,840	2,744
holandčina	9,191	9,316	0,410	0,476	2,847	2,768
španielčina	9,467	9,419	0,483	0,564	2,661	2,594
taliančina	8,063	8,300	0,441	0,524	2,739	2,681
portugalčina	8,911	8,984	0,470	0,564	2,681	2,607

Tabuľka 3.11: Priemerný stupeň $\langle k \rangle$, koeficient zhľukovania C a priemerná najkratšia vzdialenosť $\langle d \rangle$ pre lematizované texty s označením bez/s pre siete bez interpunkcie a s interpunkciou

Priemerný stupeň $\langle k \rangle$ po lematizácii vzrástol vo všetkých jazykoch približne o 1 až 2 stupne. Najvýraznejší nárast sme zaznamenali pri španielčine (o 2,19), nasledovanej portugalčinou (o 1,55) a taliančinou (o 1,44). Opäť tak pozorujeme najväčšie rozdiely pri románskych jazykoch, čo potvrdzuje, že proces lematizácie má na ich sieťovú štruktúru najzásadnejší vplyv. Zaujímavý je prípad taliančiny, ktorá mala v pôvodných

sieťach najnižšiu hodnotu priemerného stupňa a po lematizácii sa vyšplhala na tretie miesto. Najvyššiu hodnotu priemerného stupňa si aj tak stále udržiava angličtina, keďže je to analytický jazyk.

Aj koeficient zhlučovania C sa zvýšil vo všetkých jazykoch, pričom najvýraznejšie zmeny opäť nastali v románskych jazykoch. Najväčší nárast (o 122 %) zaznamenala taliančina, nasledovaná portugalčinou (o 60 %) a španielčinou (o 54 %). Tento prudký nárast u románskych jazykov potvrdzuje, že v ich pôvodných textoch vysoká morfológická variabilita umelo izolovala súvisiace pojmy. Rôzne tvary toho istého slova sa v sieti vyskytovali ako samostatné uzly na rôznych miestach, čo bránilo vytváraniu prepojených lokálnych štruktúr. Podstatne menší nárast bol v holandčine (o 21%) a angličtine (len o 13%). V prípade angličtiny je hodnota C po lematizácii stále vysoká, no na rozdiel od pôvodných textov už nie je najvyššia spomedzi všetkých jazykov.

Priemerná dĺžka najkratšej cesty $\langle d \rangle$ sa po lematizácii vo všetkých jazykoch skrátila, čo je v súlade s nárastom hustoty a priemerného stupňa uzlov. Najvýraznejší pokles opäť zaznamenala taliančina (o 0,41), nasledovaná portugalčinou (o 0,29), nemčinou (o 0,26) a španielčinou (o 0,25). Menší pokles sme zaznamenali pri holandčine (o 0,10) a najmenší rozdiel má angličtina (o 0,08).


Z pohľadu teórie malého sveta sa po lematizácii znížila priemerná vzdialenosť, čo spolu so zvýšeným koeficientom zhlučovania vedie k ešte výraznejším vlastnostiam malého sveta. Sieť sa stáva hustejšou, informácia medzi slovami putuje rýchlejšie a jazyk ako systém je efektívnejší.

Po pridání interpunkcie v lematizovaných textoch sa všetky tri metriky menili len nepatrne a nedochádza k výrazným a neočakávaným zmenám. Správanie interpunkcie bolo v podstate rovnaké ako v pôvodných textoch.

3.4.3 Distribúcia stupňov uzlov po lematizácii

Distribúcia stupňov uzlov nám umožňuje overiť, či aj po zjednotení slovných tvarov zostávajú siete bezškálové, a sledovať, ako sa zmenil škálovací exponent γ v porovnaní s pôvodnými textami. Lematizácia výrazne znižuje počet uzlov, čo môže ovplyvniť charakter mocninového rozdelenia.

Z obrázku 3.6 možno vidieť, že distribúcia stupňov uzlov vo všetkých šiestich jazykoch aj po lematizácii nasleduje mocninový zákon, a to od hodnoty x_{min} . Škálovací exponent γ nadobúda hodnoty v rozmedzí približne 2,069 až 2,18, pričom najnižšiu hodnotu dosahuje holandčina a najvyššiu španielčina. V porovnaní s pôvodnými textami bez interpunkcie nedošlo k výrazným zmenám – hodnoty γ zostali v intervale $2 < \gamma < 3$. Lematizované siete taktiež vykazujú rovnaké bezškálové vlastnosti ako pôvodné siete. Zmeny však nie sú rovnakého charakteru. Po lematizácii textu hodnoty exponentov γ stúpili, aj klesli. Kým v angličtine, španielčine a portugalčine sme za-




Obr. 3.6: Distribúcia stupňov uzlov pre siete z lematizovaných textov bez interpunkcie - závislosť pravdepodobnosti $P(k)$ od stupňa uzla k v log-log mierke. Čierne body predstavujú empirické dáta, červená prerušovaná priamka znázorňuje správanie podľa mocninového zákona s exponentom γ .

znamenalí nárast γ (čo zodpovedá menej výrazným hubom), v nemčine, holandčine a taliančine došlo k jeho poklesu (výraznejšie huby). Tieto zmeny naznačujú, že vplyv lematizácie na distribúciu stupňov nie je jednotný a nezávisí priamo od jazykovej rodiny. Zároveň ukazuje, že lematizácia vplýva na hierarchickú štruktúru sietí rôznymi spôsobmi v závislosti od konkrétnej morfológie daného jazyka.

Okrem samotného exponentu γ sa po lematizácii zmenila aj hodnota x_{min} . Pri pôvodných textoch sa táto hodnota pohybovala v širokom rozmedzí od 6 (angličtina) až po 17 (holandčina). Po lematizácii došlo k zaujímavému posunu – v jazykoch s pôvodne nízkym x_{min} (angličtina, španielčina, portugalčina) sa táto hranica zvýšila, zatiaľ čo v jazykoch s pôvodne vysokým x_{min} (nemčina, holandčina, taliančina) klesla. Pokles môže naznačovať, že lematizácia odstránila množstvo slabých prepojení a sprístupnila mocninové správanie už od nižších stupňov. Nárast môže naopak odrážať, že po zlúčení slovných tvarov vzniklo viac uzlov s nízkym stupňom, ktoré sa od mocninového rozdelenia odchyľujú. Kým v pôvodných sieťach bol rozptyl x_{min} pomerne veľký, po lematizácii sa toto rozpätie zúžilo na interval 6 až 12.

Pozrime sa na vplyv interpunkcie na distribúciu stupňov po jej zahrnutí do lematizovaných sietí (obrázok 3.7). Hodnoty exponentu sa pohybujú v rozmedzí od 2,08 do 2,149, kde má najvyššiu hodnotu γ taliančina a najnižšiu znova holandčina. V porovnaní s lematizovanými sieťami bez interpunkcie došlo k zmenám – v angličtine, španielčine a portugalčine hodnota γ klesla, zatiaľ čo v nemčine, holandčine a taliančine stúpla. Rozdiely sú však malé, maximálne 0,05. Zahrnutie interpunkčných znamienok nespôsobilo zásadný topologický zvrät v charaktere distribúcie.

Hoci lematizácia a pridanie interpunkcie jemne modulujú konkrétne hodnoty škálovacích parametrov, základná architektúra slovných sietí zostáva zachovaná a siete si udržiavajú bezškálovosť. Rozdiely v morfológii jednotlivých jazykov výrazne ovplyvňujú povrchovú štruktúru textu, ale po lematizácii sa tieto rozdiely čiastočne znižujú – najvýraznejšie zmeny nastávajú práve v románskych jazykoch, ktoré sa približujú k hodnotám germánskych jazykov, no úplne sa nezblížujú. Každý jazyk si aj po zjednotení slovných tvarov zachováva špecifické črty svojej sieťovej štruktúry.



Obr. 3.7: Distribúcia stupňov uzlov pre siete z lematizovaných textov s interpunkciou - závislosť pravdepodobnosti $P(k)$ od stupňa uzla k v log-log mierke. Čierne body predstavujú empirické dáta, červená prerušovaná priamka znázorňuje správanie podľa mocninového zákona s exponentom γ .

Záver

Cieľom tejto bakalárskej práce bolo analyzovať a porovnať vlastnosti slovných sietí vytvorených z rovnakého textového korpusu pri dvoch rôznych prístupoch – so zahrnutím interpunkčných znamienok a bez ich zahrnutia. Na dosiahnutie tohto cieľa bolo využitých šesť jazykových verzií Kafkovej novely *Premena*, reprezentujúcich germánsku a románsku jazykovú rodinu. Výber jediného diela v rôznych jazykoch umožnil izolovať vplyv jazykovej štruktúry od vplyvu sémantického obsahu textu.

Teoretická časť práce predstavila základné pojmy z teórie grafov, matematickej lingvistiky a teórie komplexných sietí, pričom osobitná pozornosť bola venovaná slovným sieťam, ich typom a vlastnostiam. Boli vysvetlené kvantitatívne zákonitosti prirodzeného jazyka, predovšetkým Zipfov a Heapsov zákon, ako aj vlastnosti reálnych komplexných sietí, ako sú bezškálovosť a efekt malého sveta. Tieto teoretické základy tvorili nevyhnutný rámec pre následnú empirickú analýzu.

V praktickej časti boli texty v šiestich jazykoch manuálne predspracované s ohľadom na špecifiká každého jazyka, tokenizované a transformované do podoby syntaktických slovných sietí. Pre každý jazyk vznikli štyri varianty sietí podľa toho, či bol text lematizovaný a či boli do siete zahrnuté interpunkčné znamienka. Analýza zahŕňala výpočet základných topologických metrík, skúmanie frekvencie tokenov, overenie platnosti Zipfovho a Heapsovho zákona a analýzu distribúcie stupňov uzlov.

Výsledky ukázali, že všetky skúmané siete majú vlastnosti typické pre reálne komplexné siete. Priemerná dĺžka najkratšej cesty sa pohybovala v rozmedzí od 2,7 do 3,1, čo je pri tisíckach uzlov veľmi nízka hodnota, a koeficient zhlukovania dosahoval pomerne vysoké čísla – obe tieto skutočnosti potvrdzujú efekt malého sveta. Distribúcia stupňov uzlov vo všetkých jazykoch a vo všetkých variantoch sietí sledovala mocninový zákon so škálovacím exponentom v intervale $2 < \gamma < 3$, čo potvrdzuje bezškálový charakter slovných sietí. Hodnoty Zipfovho exponentu α sa pohybovali v rozmedzí od 0,912 do 1,18, teda v súlade s teoretickými predpokladmi pre prirodzené jazyky.

Zistené rozdiely medzi jazykmi majú jasnú príčinu v ich morfologickej a syntaktickej štruktúre. Angličtina ako analytický jazyk s minimálnym ohýbaním slov dosahuje najnižší počet uzlov, najvyššiu hustotu a najvyšší priemerný stupeň. Toto považujeme za dôsledok toho, že v angličtine sa ten istý lexikálny základ opakuje v texte v rovnakom tvare, čím vzniká menej unikátnych uzlov, ale tieto uzly sú navzájom hustejšie prepo-

jené. Naopak, taliančina ako morfológicky bohatý flektívny jazyk vytvára v pôvodnom texte množstvo rôznych tvarov toho istého slova, čo vedie k vyššiemu počtu uzlov, redšej štruktúre a dlhším cestám medzi slovami. Tieto rozdiely sú primárne dôsledkom jazykovej typológie, nie obsahu textu.

Zahrnutie interpunkčných znamienok do sietí viedlo k miernemu nárastu počtu uzlov, počtu hrán, priemerného stupňa a koeficientu zhukovania a k miernemu poklesu priemernej dĺžky najkratšej cesty. Interpunkčné znamienka sa správajú ako vysoko prepojené huby a fungujú ako efektívne skratky v sieti. Čiarka sa vo všetkých analyzovaných jazykoch umiestnila na prvom mieste v rebríčku frekvencie, čo je v súlade s výsledkami Kuliga a kol. Zahrnutie interpunkcie zároveň zlepšilo škálovanie Zipfovho rozdelenia v oblasti najvyšších frekvencií. Škálovací exponent γ sa po pridaní interpunkcie zmenil len nepatrne, pričom smer tejto zmeny nebol jednotný naprieč jazykmi. Vysvetľujeme to rozdielnou mierou dominancie interpunkčných znamienok oproti pôvodným slovám – v niektorých jazykoch sa čiarka a bodka stali výraznejšími hubmi, v iných len mierne doplnili existujúce huby (členy, spojky). Napriek týmto jemným rozdielom si všetky siete zachovali bezškálový charakter, čo potvrdzuje, že interpunkcia je štruktúrnou súčasťou jazykovej siete, nie cudzím prvkom.

Lematizácia mala na štruktúru sietí výraznejší vplyv než zahrnutie interpunkcie. Počet uzlov klesol vo všetkých jazykoch, pričom románske jazyky zaznamenali výraznejší pokles (v rozsahu 31 až 36 percent) v porovnaní s germánskymi (kde pokles dosahoval 17 až 22 percent). Tento rozdiel priamo odráža bohatšiu morfológiu románskych jazykov – tie isté slová v nich vystupujú v väčšom množstve rôznych gramatických tvarov, ktoré sa po lematizácii zlúčia do jedného uzla. V analytickej angličtine je takýchto tvarov podstatne menej, preto je aj efekt lematizácie slabší. Hustota sietí sa výrazne zvýšila, priemerný stupeň uzlov narástol a priemerná najkratšia cesta sa skrátila. Lematizácia teda odstraňuje povrchovú morfológickú rozmanitosť a odhaľuje hlbšiu, hustejšiu a efektívnejšiu sieťovú štruktúru, ktorá je bližšia sémantickej organizácii jazyka. Najvýraznejšie zmeny nastali pri románskych jazykoch, ktoré disponujú bohatšou morfológiou. Napriek týmto zmenám zostal bezškálový charakter sietí zachovaný, čo svedčí o stabilite tejto topologickej vlastnosti naprieč rôznymi úrovňami spracovania textu.

Zaujímavou otázkou pre nadväzujúci výskum by bolo rozšírenie analýzy o slovenský jazyk, ktorý ako flektívny slovanský jazyk s bohatou morfológiou predstavuje odlišný jazykový typ v porovnaní s germánskymi a románskymi jazykmi. Praktickou komplikáciou je však absencia slovenského jazykového modelu v knižnici spaCy – riešením by bolo vytvorenie vlastného lematizátora pre slovenčinu. Ďalší zaujímavý smer výskumu by predstavovala analýza korelácií stupňov uzlov, teda skúmanie toho, či sa v jazykových sieťach huby spájajú prednostne s inými hubmi, alebo naopak s uzlami nízkych stupňov. Táto vlastnosť by mohla odhaliť ďalšie hlbšie štrukturálne rozdiely

medzi jazykovými rodinami. Za zmienku stojí aj možnosť analýzy väčšieho počtu textov od toho istého autora alebo textov rôznych žánrov, čo by umožnilo oddeliť vplyv autorského štýlu od vplyvu jazykovej štruktúry.

Táto práca ukázala, že slovné siete vytvorené z toho istého textu v rôznych jazykoch zdieľajú základné štrukturálne vlastnosti charakteristické pre reálne komplexné siete, no zároveň odrážajú špecifické morfológické a syntaktické vlastnosti jednotlivých jazykov. Kľúčovým zistením je, že morfológická bohatosť jazyka sa prejavuje predovšetkým na povrchovej úrovni – zvyšuje počet unikátnych uzlov a riedi štruktúru siete – zatiaľ čo hlboké topologické vlastnosti (bezškálovosť, efekt malého sveta) zostávajú univerzálne naprieč všetkými skúmanými jazykmi. Interpunkcia sa potvrdila ako štatisticky relevantná súčasť jazykovej siete, ktorá jej štruktúru jemne moduluje, no nemení jej základný charakter.

Literatúra

- [1] Marcel Ausloos. Punctuation effects in english and esperanto texts. *CoRR*, abs/1004.4848, 2010.
- [2] Albert-László Barabási. Network science. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 371(1987), 2013.
- [3] Béla Bollobás. *Modern graph theory*, volume 184. Springer Science & Business Media, 1998.
- [4] Ramon Ferrer I Cancho and Richard V Solé. The small world of human language. *Proceedings of the Royal Society of London. Series B: Biological Sciences*, 268(1482):2261–2265, 2001.
- [5] Bernard Comrie. *Language universals and linguistic typology: Syntax and morphology*. University of Chicago press, 1989.
- [6] Reinhard Diestel. *Graph Theory*, volume 173 of *Graduate Texts in Mathematics*. Springer, Berlin, Heidelberg, fifth edition, 2017.
- [7] Michał Dolina, Jakub Dec, Stanisław Drożdż, Jarosław Kwapień, Jin Liu, and Tomasz Stanisław. Quantifying patterns of punctuation in modern chinese prose. *Chaos: An Interdisciplinary Journal of Nonlinear Science*, 35(2), February 2025.
- [8] Giorgio Fagiolo. Clustering in complex directed networks. *Physical Review E*, 76(2), August 2007.
- [9] Francesc Font-Clos, Gemma Boleda, and Alvaro Corral. A scaling law beyond zipf’s law and its relation to heaps’ law. *New Journal of Physics*, 15, 09 2013.
- [10] Franz Kafka. *La metamorfosi e altri racconti (Biblioteca economica Newton)*. Newton Compton, January 2002.
- [11] Malcolm Hyman. *Semantic Networks: A Tool for Investigating Conceptual Change and Knowledge Transfer in the History of Science*, pages 355–368. 12 2007.
- [12] Franz Kafka. *A Metamorfose*. 1915.

- [13] Franz Kafka. *La metamorfosis*. Planeta Colombiana 1985, 1960.
- [14] Franz Kafka. *De gedaanteverwisseling*. Amsterdam : Athenaeum-Polak & Van Genneep, 2003.
- [15] Franz Kafka. *Metamorphosis*. Project Gutenberg, aug 2005. Pôvodne publikované v roku 1915.
- [16] Franz Kafka. *Die Verwandlung*. Project Gutenberg, aug 2007. Pôvodne publikované v roku 1915.
- [17] Aravind Kannan. Introduction to linguistics. online resource.
- [18] Reinhard Köhler. *Quantitative syntax analysis*, volume 65. Walter de Gruyter, 2012.
- [19] Andrzej Kulig, Jaroslaw Kwapień, Tomasz Stanisław, and Stanisław Drozd. In narrative texts punctuation marks obey the same statistics as words. *CoRR*, abs/1604.00834, 2016.
- [20] Linyuan Lü, Zi-Ke Zhang, and Tao Zhou. Deviation of zipf's and heaps' laws in human languages with limited dictionary sizes. *Scientific reports*, 3(1):1082, 2013.
- [21] John Lyons. *Language and linguistics*. Cambridge university press, 1981.
- [22] Linyuan Lü, Zi-Ke Zhang, and Tao Zhou. Zipf's law leads to heaps' law: Analyzing their relation in finite-size systems. *PLOS ONE*, 5(12):1–11, 12 2010.
- [23] Mária Markošová. Dynamika sietí. *Umelá inteligencia a kognitívna veda II*, pages 321–379.
- [24] Mária Markošová. Network model of human language. *Physica A Statistical and Theoretical Physics*, 387:661, 09 2008.
- [25] Stanley Milgram et al. The small world problem. *Psychology today*, 2(1):60–67, 1967.
- [26] Adilson Motter, Alessandro Moura, Ying-Cheng Lai, and Partha Dasgupta. Topology of the conceptual network of language. *Physical review. E, Statistical, nonlinear, and soft matter physics*, 65:065102, 07 2002.
- [27] Gowher Ahmad Naik, editor. *Linguistics I*. Lovely Professional University, Punjab, India.

- [28] Marianne Santaholma. Grammar sharing techniques for rule-based multilingual NLP systems. In Joakim Nivre, Heiki-Jaan Kaalep, Kadri Muischnek, and Mare Koit, editors, *Proceedings of the 16th Nordic Conference of Computational Linguistics (NODALIDA 2007)*, pages 253–260, Tartu, Estonia, May 2007. University of Tartu, Estonia.
- [29] Abbosova Sarvinozbonu and Gulyora Ismoilova. The general overview of roman-germanic language and the classification of roman-germanic languages. In *INTERNATIONAL CONFERENCE ON MULTIDISCIPLINARY STUDIES AND EDUCATION*, volume 2, pages 19–26, 2025.
- [30] Satu Elisa Schaeffer. Graph clustering. *Computer science review*, 1(1):27–64, 2007.
- [31] David W Scott. Histogram. *Wiley Interdisciplinary Reviews: Computational Statistics*, 2(1):44–48, 2010.
- [32] Blanka Sedláčková. *Historie matematické lingvistiky*. Akademické nakladatelství CERM v Brně, 2012.
- [33] Man-Keung Siu. Introduction to graph theory (4th edition), by robin j. wilson. pp. 171. £14.99. 1996. isbn : 0-582-24993-7 (longman). *The Mathematical Gazette*, 82:343 – 344, 1998.
- [34] Kun Sun and Rong Wang. Frequency distributions of punctuation marks in english: Evidence from large-scale corpora. *English Today*, 12 2018.
- [35] Marie Těšitelová. Quantitative linguistics. 1992.
- [36] Md Jashim Uddin. Exploring the depths of modern life as reflected in franz kafka’s the metamorphosis. *IUBAT Review*, 6(2):131–157, 2023.
- [37] Stanley Wasserman and Katherine Faust. Social network analysis: Methods and applications. 1994.
- [38] Duncan J. Watts and Steven H. Strogatz. Collective dynamics of ‘small-world’ networks. *nature*, 393(6684):440–442, 1998.

Zdrojový kód programu

Hoci táto práca nie je primárne zameraná na programovanie ani na vývoj softvéru, v rámci nej bol implementovaný program na tvorbu slovných sietí a ich následnú analýzu. Bola vytvorená iba veľmi jednoduchá vizualizácia, ktorá slúži na lepšie orientovanie sa v programe a uľahčuje analýzu konkrétnych vlastností skúmanej slovnej siete. Tento program slúžil ako nástroj na získanie všetkých experimentálnych výsledkov uvedených v práci.

Zdrojový kód programu je verejne dostupný na GitHub repozitári a obsahuje kompletný zdrojový kód, zoznam potrebných knižníc a modulov pre knižnicu `spaCy`:

https://github.com/murajdas/bakalarska_praca